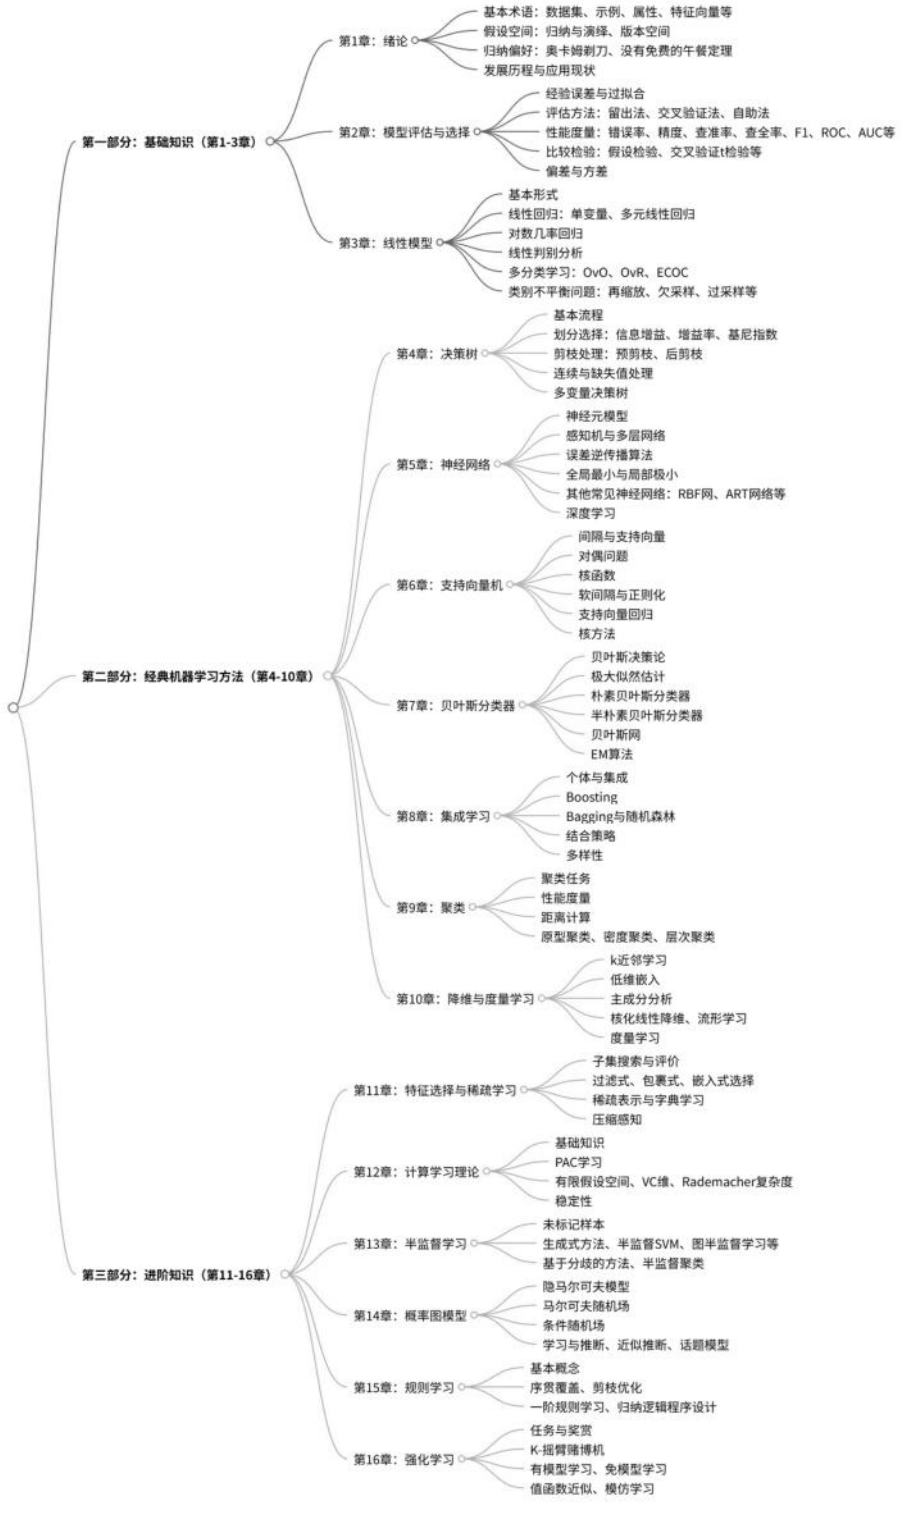
機器學習


第一部分：基础知识（第1-3章）
第1章：绪论
基本术语：数据集、示例、属性、特征向量等
假设空间：归纳与演绎、版本空间
归纳偏好：奥卡姆剃刀、没有免费的午餐定理
发展历程与应用现状
第2章：模型评估与选择
经验误差与过拟合
评估方法：留出法、交叉验证法、自助法
性能度量：错误率、精度、查准率、查全率、F1、ROC、AUC等
比较检验：假设检验、交叉验证t检验等
偏差与方差
第3章：线性模型
基本形式
线性回归：单变量、多元线性回归
对数几率回归
线性判别分析
多分类学习：OvO、OvR、ECOC
类别不平衡问题：再缩放、欠采样、过采样等
第二部分：经典机器学习方法（第4-10章）
第4章：决策树
基本流程
划分选择：信息增益、增益率、基尼指数
剪枝处理：预剪枝、后剪枝
连续与缺失值处理
多变量决策树
第5章：神经网络
神经元模型
感知机与多层网络
误差逆传播算法
全局最小与局部极小
其他常见神经网络：RBF网、ART网络等
深度学习
第6章：支持向量机
间隔与支持向量
对偶问题
核函数
软间隔与正则化
支持向量回归
核方法
第7章：贝叶斯分类器
贝叶斯决策论
极大似然估计
朴素贝叶斯分类器
半朴素贝叶斯分类器
贝叶斯网
EM算法
第8章：集成学习
个体与集成
Boosting
Bagging与随机森林
结合策略
多样性
第9章：聚类
聚类任务
性能度量
距离计算
原型聚类、密度聚类、层次聚类
第10章：降维与度量学习
k近邻学习
低维嵌入
主成分分析
核化线性降维、流形学习
度量学习
第三部分：进阶知识（第11-16章）
第11章：特征选择与稀疏学习
子集搜索与评价
过滤式、包裹式、嵌入式选择
稀疏表示与字典学习
压缩感知
第12章：计算学习理论
基础知识
PAC学习
有限假设空间、VC维、Rademacher复杂度
稳定性
第13章：半监督学习
未标记样本
生成式方法、半监督SVM、图半监督学习等
基于分歧的方法、半监督聚类
第14章：概率图模型
隐马尔可夫模型
马尔可夫随机场
条件随机场
学习与推断、近似推断、话题模型
第15章：规则学习
基本概念
序贯覆盖、剪枝优化
一阶规则学习、归纳逻辑程序设计
第16章：强化学习
任务与奖赏
K-摇臂赌博机
有模型学习、免模型学习
值函数近似、模仿学习

第 1 章 绪论

- 机器学习（machine learning）
- 数据集（data set）
- 示例 / 样本（instance/sample）
- 属性 / 特征（attribute/feature）
- 属性值（attribute value）
- 属性空间 / 样本空间 / 输入空间（attribute space/sample space/input space）
- 特征向量（feature vector）
- 学习 / 训练（learning/training）
- 训练数据 / 训练样本 / 训练集（training data/training sample/training set）
- 假设（hypothesis）
- 真相 / 真实（ground-truth）
- 学习器（learner）
- 标记（label）
- 样例（example）
- 分类（classification）
- 回归（regression）
- 二分类（binary classification）
- 正类 / 反类（positive class/negative class）
- 多分类（multi-class classification）
- 测试（testing）
- 测试样本（testing sample）
- 聚类（clustering）
- 簇（cluster）
- 监督学习（supervised learning）
- 无监督学习（unsupervised learning）
- 泛化（generalization）
- 独立同分布（independent and identically distributed, i.i.d.）
- 归纳（induction）
- 演绎（deduction）
- 归纳学习（inductive learning）
- 版本空间（version space）
- 归纳偏好（inductive bias）
- 奥卡姆剃刀（Occam's razor）
- 没有免费的午餐定理（No Free Lunch Theorem, NFL）

第 2 章 模型评估与选择

- 错误率（error rate）
- 精度（accuracy）
- 误差（error）
- 训练误差 / 经验误差（training error/empirical error）
- 泛化误差（generalization error）
- 过拟合（overfitting）
- 欠拟合（underfitting）
- 模型选择（model selection）
- 测试集（testing set）
- 测试误差（testing error）
- 留出法（hold-out）
- 交叉验证法（cross validation）
- k 折交叉验证（k-fold cross validation）
- 留一法（Leave-One-Out, LOO）
- 自助法（bootstrapping）
- 包外估计（out-of-bag estimate）
- 调参（parameter tuning）
- 验证集（validation set）
- 均方误差（mean squared error）
- 查准率（precision）
- 查全率（recall）
- 混淆矩阵（confusion matrix）
- 真正例（true positive, TP）/ 假正例（false positive, FP）
- 真反例（true negative, TN）/ 假反例（false negative, FN）
- P-R 曲线（Precision-Recall curve）
- 平衡点（Break-Event Point, BEP）
- F1 度量（F1 measure）
- Fβ 度量（Fβ measure）
- 宏查准率 / 宏查全率 / 宏 F1（macro-P/macro-R/macro-F1）
- 微查准率 / 微查全率 / 微 F1（micro-P/micro-R/micro-F1）
- ROC 曲线（Receiver Operating Characteristic curve）
- AUC（Area Under ROC Curve）
- 排序损失（rank loss）
- 代价敏感错误率（cost-sensitive error rate）
- 代价矩阵（cost matrix）
- 代价曲线（cost curve）
- 假设检验（hypothesis test）
- 二项检验（binomial test）
- t 检验（t-test）
- 交叉验证 t 检验（paired t-test）
- 5×2 交叉验证（5×2 cross validation）
- McNemar 检验（McNemar's test）
- Friedman 检验（Friedman test）
- Nemenyi 后续检验（Nemenyi post-hoc test）
- 偏差（bias）
- 方差（variance）
- 噪声（noise）

第 3 章 线性模型

- 线性模型（linear model）
- 线性回归（linear regression）
- 多元线性回归（multivariate linear regression）
- 最小二乘法（least square method）
- 对数线性回归（log-linear regression）
- 广义线性模型（generalized linear model）
- 联系函数（link function）
- 对数几率回归（logistic regression）
- 单位阶跃函数（unit-step function）
- 对数几率函数（logistic function）
- Sigmoid 函数（Sigmoid function）

- 线性判别分析（Linear Discriminant Analysis, LDA）
- 类内散度矩阵（within-class scatter matrix）
- 类间散度矩阵（between-class scatter matrix）
- 广义瑞利商（generalized Rayleigh quotient）
- 多分类学习（multi-class learning）
- 一对一（One vs. One, OvO）
- 一对其余（One vs. Rest, OvR）
- 多对多（Many vs. Many, MvM）
- 纠错输出码（Error Correcting Output Codes, ECOC）
- 类别不平衡（class-imbalance）
- 再缩放（rescaling）
- 欠采样（undersampling）
- 过采样（oversampling）
- 阈值移动（threshold-moving）

第 4 章 决策树

- 决策树（decision tree）
- 分而治之（divide-and-conquer）
- 信息熵（information entropy）
- 信息增益（information gain）
- ID3 算法（ID3 algorithm）
- 增益率（gain ratio）
- C4.5 算法（C4.5 algorithm）
- 固有值（intrinsic value）
- 基尼指数（Gini index）
- CART 算法（CART algorithm）
- 剪枝（pruning）
- 预剪枝（prepruning）
- 后剪枝（post-pruning）
- 决策树桩（decision stump）
- 连续值处理（continuous value handling）
- 二分法（bi-partition）
- 缺失值处理（missing value handling）
- 多变量决策树（multivariate decision tree）

第 5 章 神经网络

- 神经网络（neural networks）
- 神经元（neuron）
- M-P 神经元模型（M-P neuron model）
- 激活函数（activation function）
- 感知机（Perceptron）
- 阈值逻辑单元（threshold logic unit）
- 多层网络（multi-layer network）
- 隐层（hidden layer）
- 多层前馈神经网络（multi-layer feedforward neural networks）
- 误差逆传播算法（Error BackPropagation, BP）
- 标准 BP 算法（standard BP algorithm）
- 累积 BP 算法（accumulated error BP algorithm）
- 早停（early stopping）
- 正则化（regularization）
- 局部极小（local minimum）
- 全局最小（global minimum）
- 模拟退火（simulated annealing）
- 随机梯度下降（stochastic gradient descent）
- RBF 网络（Radial Basis Function network）
- 竞争型学习（competitive learning）
- 胜者通吃（winner-take-all）
- ART 网络（Adaptive Resonance Theory network）
- 增量学习（incremental learning）
- 在线学习（online learning）
- SOM 网络（Self-Organizing Map network）
- 级联相关网络（Cascade-Correlation network）
- 递归神经网络（recurrent neural networks）
- Elman 网络（Elman network）
- Boltzmann 机（Boltzmann machine）
- 受限 Boltzmann 机（Restricted Boltzmann Machine, RBM）
- 对比散度（Contrastive Divergence, CD）
- 深度学习（deep learning）
- 深度信念网络（deep belief network, DBN）
- 预训练（pre-training）
- 微调（fine-tuning）
- 卷积神经网络（Convolutional Neural Network, CNN）

第 6 章 支持向量机

- 支持向量机（Support Vector Machine, SVM）
- 划分超平面（separating hyperplane）
- 间隔（margin）
- 支持向量（support vector）
- 最大间隔（maximum margin）
- 凸二次规划（convex quadratic programming）
- 对偶问题（dual problem）
- KKT 条件（Karush-Kuhn-Tucker conditions）
- SMO 算法（Sequential Minimal Optimization algorithm）
- 核函数（kernel function）
- 核技巧（kernel trick）
- 线性核（linear kernel）/ 多项式核（polynomial kernel）
- 高斯核（Gaussian kernel）/ 拉普拉斯核（Laplacian kernel）
- 再生核希尔伯特空间（Reproducing Kernel Hilbert Space, RKHS）
- 软间隔（soft margin）/ 硬间隔（hard margin）
- 0/1 损失函数（0/1 loss function）
- 替代损失（surrogate loss）
- hinge 损失（hinge loss）/ 指数损失（exponential loss）
- 对率损失（logistic loss）
- 松弛变量（slack variables）
- 正则化（regularization）
- 支持向量回归（Support Vector Regression, SVR）

- ε 不敏感损失（ε-insensitive loss）
- 表示定理（representer theorem）
- 核方法（kernel methods）

第 7 章 贝叶斯分类器

- 贝叶斯决策论（Bayesian decision theory）
- 期望损失（expected loss）
- 条件风险（conditional risk）
- 贝叶斯最优分类器（Bayes optimal classifier）
- 贝叶斯风险（Bayes risk）
- 判别式模型（discriminative models）
- 生成式模型（generative models）
- 先验概率（prior probability）
- 类条件概率（class-conditional probability）
- 似然（likelihood）
- 证据因子（evidence）
- 极大似然估计（Maximum Likelihood Estimation, MLE）
- 对数似然（log-likelihood）
- 朴素贝叶斯分类器（naive Bayes classifier）
- 属性条件独立性假设（attribute conditional independence assumption）
- 拉普拉斯修正（Laplacian correction）
- 半朴素贝叶斯分类器（semi-naive Bayes classifiers）
- 独依赖估计（One-Dependent Estimator, ODE）
- TAN（Tree Augmented naive Bayes）
- 条件互信息（conditional mutual information）
- AODE（Averaged One-Dependent Estimator）
- 贝叶斯网（Bayesian network）
- 信念网（belief network）
- 有向无环图（Directed Acyclic Graph, DAG）
- EM 算法（Expectation-Maximization algorithm）

第 8 章 集成学习

- 集成学习（ensemble learning）
- 个体学习器（base learner）
- 同质集成（homogeneous ensemble）/ 异质集成（heterogeneous ensemble）
- Boosting 算法
- Bagging 算法
- 随机森林（Random Forest）
- 结合策略（combination strategies）
  - 投票法（voting）
  - 平均法（averaging）
  - 堆叠法（stacking）
- 多样性（diversity）
  - 误差 - 分歧分解（error-ambiguity decomposition）
  - 多样性度量（diversity measures）

第 9 章 聚类

- 聚类（clustering）
- 性能度量
  - 外部指标（external indices）：兰德指数（Rand Index, RI）、纯度（purity）等
  - 内部指标（internal indices）：DB 指数（Davies-Bouldin Index, DBI）、轮廓系数（silhouette coefficient）等
- 距离计算
  - 闵可夫斯基距离（Minkowski distance）
  - 欧氏距离（Euclidean distance）
  - 曼哈顿距离（Manhattan distance）
  - 余弦相似度（cosine similarity）
- 原型聚类（prototype-based clustering）：k 均值（k-means）、学习向量量化（Learning Vector Quantization, LVQ）等
- 密度聚类（density-based clustering）：DBSCAN 算法、OPTICS 算法等
- 层次聚类（hierarchical clustering）：AGNES 算法、DIANA 算法等

第 10 章 降维与度量学习

- k 近邻学习（k-nearest neighbor, kNN）
- 低维嵌入（low-dimensional embedding）
- 主成分分析（Principal Component Analysis, PCA）
- 核化线性降维（kernelized linear dimensionality reduction）：核 PCA（Kernel PCA）等
- 流形学习（manifold learning）：等距映射（Isometric Mapping, Isomap）、局部线性嵌入（Locally Linear Embedding, LLE）等
- 度量学习（metric learning）

第 11 章 特征选择与稀疏学习

- 特征选择（feature selection）
- 子集搜索（subset search）：向前搜索、向后搜索、双向搜索
- 子集评价（subset evaluation）
- 过滤式选择（filter selection）
- 包裹式选择（wrapper selection）
- 嵌入式选择（embedded selection）
- L1 正则化（L1 regularization）
- 稀疏表示（sparse representation）
- 字典学习（dictionary learning）
- 压缩感知（compressed sensing）

第 12 章 计算学习理论

- 计算学习理论（computational learning theory）
- PAC 学习（Probably Approximately Correct learning）
- 有限假设空间（finite hypothesis space）
- VC 维（Vapnik-Chervonenkis dimension）
- 增长函数（growth function）
- 粉碎（shattering）

- Rademacher 复杂度（Rademacher complexity）
- 稳定性（stability）：均匀稳定性（uniform stability）等

第 13 章 半监督学习

- 半监督学习（semi-supervised learning）
- 未标记样本（unlabeled sample）
- 生成式方法（generative methods）
- 半监督 SVM（semi-supervised SVM）
- 图半监督学习（graph-based semi-supervised learning）
- 基于分歧的方法（disagreement-based methods）：协同训练（co-training）、协同正则化（co-regularization）等
- 半监督聚类（semi-supervised clustering）

第 14 章 概率图模型

- 概率图模型（probabilistic graphical models）
- 隐马尔可夫模型（Hidden Markov Model, HMM）
- 马尔可夫随机场（Markov Random Field, MRF）
- 条件随机场（Conditional Random Field, CRF）
- 学习（learning）与推断（inference）
- 近似推断（approximate inference）：信念传播（Belief Propagation）、变分推断（variational inference）等
- 话题模型（topic model）：潜在狄利克雷分配（Latent Dirichlet Allocation, LDA）等

第 15 章 规则学习

- 规则学习（rule learning）
- 规则（rule）：体（body）、头（head）
- 规则集（rule set）
- 序贯覆盖（sequential covering）
- 剪枝优化（pruning optimization）：预剪枝、后剪枝（如减错剪枝 REP、增广减错剪枝 IREP 等）
- 一阶规则学习（first-order rule learning）
- 归纳逻辑程序设计（Inductive Logic Programming, ILP）

第 16 章 强化学习

- 强化学习（reinforcement learning）
- 任务与奖赏（task and reward）：马尔可夫决策过程（Markov Decision Process, MDP）
- K - 摇臂赌博机（K-armed bandit）
- 有模型学习（model-based learning）
- 免模型学习（model-free learning）：Q 学习（Q-learning）、Sarsa 算法等
- 值函数近似（value function approximation）
- 策略梯度（policy gradient）
- 模仿学习（imitation learning）

第2章 模型评估与选择

样本划分方法

1、留出法：将数据集划分为两个互斥的集合

、 分层采样保持比例，常n-1用于训练

2、交叉验证法：p次k折交叉验证：划分为k个子集，不同划分p次

k=m：留一法

3、自助法：有放回采样重复m次，$m\to\infty$时有$\frac{1}{e}$出现在采样集

基本算法相关统计量

1、错误率：分类错误的样本数占总数的比例

2、精度：1-错误率

3、查准率：$P=\frac{TP}{TP+FP}$ 查到正例中的真正例率

查全率：$R=\frac{TP}{TP+FN}$ 所有正例中被查到的比率 > P-R曲线 与平衡点

F1度量：$\frac{1}{F_1}=\frac{1}{2}(\frac{1}{P}+\frac{1}{R})$ $F_1=\frac{2PR}{P+R}=\frac{2TP}{总样例+TP-TN}$

"宏(macro)"：原始数据→率→平均 数据相差很大

"微(micro)"：原始数据→平均→率 数据相差不大

4、真正例率：查全率 假正例率：1-TPR



ROC图：按序列遍历所有预测结果，正确向上，错误向右

AUC(ROC图曲线下面积)：$\frac{1}{2}\sum_{i=1}^{m}(x_{i+1}-x_i)\cdot(y_{i+1}+y_i)$

$l_{rank}=\frac{1}{m^+}\sum_{x^+\in D}\frac{1}{m^-}\sum_{x^-\in D}\left(\mathbb{I}(f(x^+)<f(x^-))+\frac{1}{2}\mathbb{I}(f(x^+)=f(x^-))\right)$

在ROC曲线中向右上方移动

$AUC=1-l_{rank}$

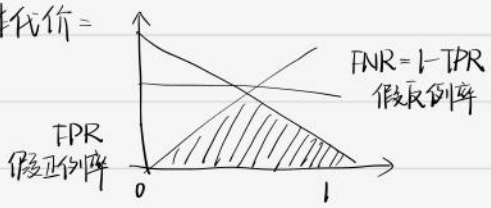
代价敏感

1、代价敏感错误率 = $E(f;D;cost) = \frac{1}{m}\left(\sum_{x_i \in D^+} \mathbb{I}(f(x_i) \neq y_i) \times cost_{01} + \sum_{x_i \in D^-} \mathbb{I}(f(x_i) \neq y_i) \times cost_{10}\right)$

2、正例概率代价 = $P(+1|cost) = \frac{p \cdot cost_{01}}{p \cdot cost_{01} + (1-p) cost_{10}}$

3、归一化代价 = $cost_{norm} = \frac{FNR \times p \times cost_{01} + FPR \times (1-p) \times cost_{10}}{p \times cost_{01} + (1-p) \times cost_{10}}$

4、期望总体代价 =



对所有样本，若其为正例则右↓，为假反例则左→

算法比较与检验

1、假设检验 = 显著性水平，置信度，p值，

t检验(σ已知，n较大)，t验检(样本好，n较小)

2、交叉验证t检验 = 基于p次k折交叉验证法

① p=1时 = 变量 $\Delta_i = \epsilon_i^A - \epsilon_i^B$ 错误率的差值

计算μ和σ，统计量 $T_t = \left|\frac{\sqrt{k}\mu}{\sigma}\right|$ ~ t(k)

② p>1时 = 变量 Δ_p^k = 第p次第k折

$\mu = \bar{\Delta}_1^k$ 只用第1次k折均值代替，每次实验均有方差 σ_i^2

$T_t = \frac{\mu}{\sqrt{\frac{1}{p}\sum_{i=1}^{p}\sigma_i^2}}$ ~ t(p)

3、McNemar检验(χ²检验)

$T_{\chi^2} = \frac{(|e_{01} - e_{10}| - 1)^2}{e_{01} + e_{10}}$ ~ $\chi^2(1)$

4. Friedman 检验和 Nemenyi 后续检验

N个数据集上比较k个算法，r_i表示算法i的平均序值

则 $r_i \sim N\left(\frac{k+1}{2}, \frac{k^2-1}{12}\right)$

$$\tau_{\chi^2} = \frac{12N}{k(k+1)}\left(\sum_{i=1}^{k} r_i^2 - \frac{k(k+1)^2}{4}\right) \sim \chi^2(k-1)$$

$$\tau_F = \frac{(N-1)\tau_{\chi^2}}{N(k-1)-\tau_{\chi^2}} \sim F(k-1, (k-1)(N-1))$$

第3章 线性模型

线性回归 (回归)

1、最小二乘法：$E(w,b)=\sum_{i=1}^{m}(y_i-wx_i-b)^2$，求最小值

将$E(w,b)$分别对w和b求导，

使其得0解出w和b最优解的闭式解

2、最小二乘法——多元线性回归

$f(x_i)=w^Tx_i+b$，使得$f(x_i)\simeq y_i$

样本处理：将数据集表示为$m\times(d+1)$的矩阵，

每行对应一个示例，最后一个元素恒为1

$$E_{\hat{w}}=(y-X\hat{w})^T(y-X\hat{w})$$

$$\frac{\partial E_{\hat{w}}}{\partial \hat{w}}=2X^T(X\hat{w}-y)$$ 令其为0得$\hat{w}$最优解的闭式解

$$\hat{w}=(X^TX)^{-1}X^Ty$$

对数几率回归 (分类)

1、对数几率函数："Sigmoid函数" $y=\frac{1}{1+e^{-z}}=\frac{1}{1+e^{-(w^Tx+b)}}$

$$\ln\frac{y}{1-y}=w^Tx+b=z$$

y=正例可能性 $=\frac{e^z}{1+e^z}$

$1-y$=反例可能性 $=\frac{1}{1+e^z}$

2、对数似然：$l(w,b)=\sum_{i=1}^{m}\ln p(y_i|x_i;w,b)$

求最大↗ $=\sum_{i=1}^{m}\ln\left(y_ip_1(x_i;w,b)+(1-y_i)p_0(x_i;w,b)\right)$

代入$\beta=(w;b)$，$\hat{x}=(x;1)$，$w^Tx+b=\beta^T\hat{x}$

求最小↘ $l(\beta)=\sum_{i=1}^{m}\left(-y_i\beta^T\hat{x}_i+\ln(1+e^{\beta^T\hat{x}_i})\right)$

关于β的高阶可导连续凸函数，梯度下降法、牛顿法

线性判别分析（监督降维）

同类投影点协方差 $\downarrow = w^T\Sigma_0 w + w^T\Sigma_1 w$，

类内散度矩阵 $S_w = \Sigma_0 + \Sigma_1 = \sum_{x_0}(x-\mu_0)(x-\mu_0)^T + \sum_{x_1}(x-\mu_1)(x-\mu_1)^T$

异类投影中心点距离 $\uparrow = \|w^T\mu_0 - w^T\mu_1\|_2^2$

类间散度矩阵 $S_b = (\mu_0-\mu_1)(\mu_0-\mu_1)^T$

$$\uparrow J = \frac{\|w^T\mu_0 - w^T\mu_1\|_2^2}{w^T\Sigma_0 w + w^T\Sigma_1 w} = \frac{w^T(\mu_0-\mu_1)(\mu_0-\mu_1)^T w}{w^T(\Sigma_0+\Sigma_1)w} = \frac{w^T S_b w}{w^T S_w w}$$

令 $w^T S_w w = 1$，使 $w^T S_b w$ 最大，$-w^T S_b w$ 最小

$S_b w$ 方向恒为 $\mu_0-\mu_1$，令 $S_b w = \lambda(\mu_0-\mu_1)$，则 $w = S_w^{-1}(\mu_0-\mu_1)$

多分类问题：

全局散度矩阵 $= S_t = S_b + S_w = \sum(x_i-\mu)(x_i-\mu)^T$

$$S_w = \sum_{i=1}^{N} S_{w_i} = \sum_{i=1}^{N}\sum_{x\in X_i}(x-\mu_i)(x-\mu_i)^2$$

$$S_b = S_t - S_w = \sum_{i=1}^{N} m_i(\mu_i-\mu)(\mu_i-\mu)^T$$

$$\uparrow J = \frac{tr(W^T S_b W)}{tr(W^T S_w W)},\quad W\in\mathbb{R}^{d\times(N-1)}$$

J 最大，W 的闭式解是 $S_w^{-1}S_b$ 的 $N-1$ 个最大广义特征值对应的特征向量所组成的矩阵

第4章 决策树

信息论

1. 信息熵 = $Ent(D) = -\sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$ 越小D越纯
2. 信息增益 = $Gain(D,a) = Ent(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} Ent(D^v)$
3. 固有值 = $IV(a) = -\sum_{v=1}^{V} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$
4. 增益率 = $Gain_ratio(D,a) = \frac{Gain(D,a)}{IV(a)}$
5. 基尼值 = $Gini(D) = 1 - \sum_{k=1}^{|\mathcal{Y}|} p_k^2$
6. 基尼指数 = $Gini_index(D,a) = \sum_{v=1}^{V} \frac{|D^v|}{|D|} Gini(D^v)$
7. 剪枝方法 = 先根据[信息增益]将分类进行排序
   ① 预剪枝 = 分支时比较分支前后泛化性能的差别
   ② 后剪枝 = 从后往前比较分支前后泛化性能的差别

样本处理

1. 连续值处理 = 设置划分点，求使信息增益最大化的划分点
2. 缺失值处理 = 分支时以不同权重(原分支的成员数)同时进入分支

   C4.5方法 = 同时探查所有分支，计算每个类别的概率，取概率最大的类别赋值给该样本

多变量决策树

每个决策树对应一个坐标图上的折线，决策一次折一次

多变量决策树对应一个斜线，处理复杂问题更灵活

第5章、神经网络

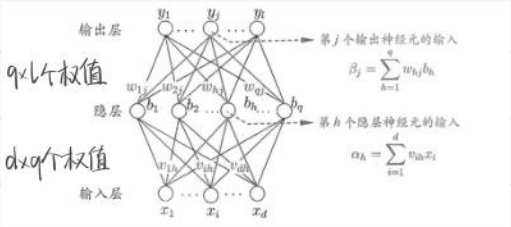
BP算法

基于Sigmoid函数：$y=\frac{1}{1+e^{-x}}$，$y'=y(1-y)$

梯度下降算法：$\Delta w_{hj}=-\eta\frac{\partial E_k}{\partial w_{hj}}$，$\eta$是学习率

对训练例(x_k,y_k)，假定神经网络输出为$\hat{y}_k=(\hat{y}_1^k,\dots,\hat{y}_l^k)$，$\hat{y}_j^k=f(\beta_j-\theta_j)$

得均方误差：$E_k=\frac{1}{2}\sum_{j=1}^{l}(\hat{y}_j^k-y_j^k)^2$



$$\frac{\partial E_k}{\partial w_{hj}}=\frac{\partial E_k}{\partial \hat{y}_j^k}\cdot\frac{\partial \hat{y}_j^k}{\partial \beta_j}\cdot\frac{\partial \beta_j}{\partial w_{hj}}\qquad \frac{\partial \beta_j}{\partial w_{hj}}=b_h$$

输出层神经元梯度项g_j
隐层神经元梯度项e_h
连接权w_{hj}、v_{ih}、阈值θ_j、γ_h

$$g_j=\frac{\partial E_k}{\partial \hat{y}_j^k}\cdot\frac{\partial \hat{y}_j^k}{\partial \beta_j}=-(\hat{y}_j^k-y_j^k)f'(\beta_j-\theta_j)=\hat{y}_j^k(1-\hat{y}_j^k)(y_j^k-\hat{y}_j^k)$$

得：$\Delta w_{hj}=\eta g_j b_h$，$\Delta\theta_j=-\eta g_j$　　$\Delta v_{ih}=\eta e_h x_i$

$$e_h=b_h(1-b_h)\sum_{j=1}^{l}w_{hj}g_j\qquad \Delta\gamma_h=-\eta e_h$$

提高神经网络的能力：

1. 累积BP算法：读取整个数据集之后再进行调参
2. "试错法"设置隐层神经元
3. 过拟合：①若训练集误差降低但验证集误差升高，则停止训练

②"正则化"：$E=\lambda\frac{1}{m}\sum_{k=1}^{m}E_k+(1-\lambda)\sum_i w_i^2$，描述网络复杂度

全局最小

1、多组初始化值

2、模拟退火：一定概率接受更差的结果

3、随机梯度下降：引入随机因素

4、遗传算法

其他神经网络

1、径向基神经网络 RBF

径向基函数：某种沿径向对称的标量函数，通常定义为样本 x 到数据中心 c_i 之间的欧氏距离的单调函数，高斯径向基函数：$\rho(x, c_i) = e^{-\beta_i \|x - c_i\|^2}$

形式化表达：$y(x) = \sum_{i=1}^{q} w_i \rho(x, c_i)$

q：隐层神经元个数，c_i：中心，w_i：权重

2、自适应谐振理论网络 ART　无监督竞争型学习、增量学习、在线学习

样本 → 比较层 → 识别层神经元 → 识别层 → 模式类　识别阈值越高越精细

输入向量和每个识别层神经元对应模式类的代表向量进行比较

与识别阈值进行比较，更新连接权 / 增设模式类

3、自组织映射网络 SOM　无监督竞争型学习

高维数据 → 匹配最佳权向量 → 调整最佳匹配单元

4. 级联相关网络：

新的隐层神经元加入时，其输入端的连接权值是冻结固定的

通过最大化新神经元的输出和网络误差的相关性训练参数

结构简单、训练较快，数据量小时易过拟合

5. Elman网络　递归神经网络

反馈输出，进一步影响下一次的输出

6. Boltzmann机　能量/状态机视角

分为显层和隐层，受限Boltzmann机不是全连接图，只连接异层

能量 $= E(s) = -\sum_{i=1}^{n-1}\sum_{j=i+1}^{n} W_{ij}S_iS_j - \sum_{i=1}^{n}\theta_i S_i$

S_i：神经元i状态 $\in \{0,1\}$，θ_i 阈值，W_{ij} 连接权

（所有"有效边"权和 + "有效点"阈值和）

对比散度CD算法：v、h 表示显层和隐层状态向量

$P(v|h) = \prod_{i=1}^{d} P(v_i|h)$　$P(h|v) = \prod_{j=1}^{q} P(h_j|v)$

$v \to P(h|v)$ 采样 $\to h \longrightarrow P(v|h)$ 采样 $\to v' \longrightarrow P(h'|v')$ 采样 $\to h'$

$\Delta w = \eta(vh^T - v'h'^T)$

深度学习 = 多隐层神经网络

1. 无监督逐层训练 = 预训练 + 微调 (RBM... + BP)

   例 = 深度信念网络, 每层都是一个受限的 Boltzmann 机

2. "权共享" = 一组神经元共享相同的连接权

   例 = 卷积神经网络, 采样层和卷积层使用一个连接权

第6章 支持向量机

超平面 = $w^T x + b = 0$

点到超平面距离 = $r = \frac{|w^T x + b|}{\|w\|}$

间隔 = $\gamma = \frac{2}{\|w\|}$

优化方向：

$$\max_{w,b} \frac{2}{\|w\|} \Big/ \min_{w,b} \frac{1}{2}\|w\|$$

$$s.t.\ y_i(w^T x_i + b) \geq 1$$

$y_i \in \{0, 1\}$，二分类

优化方法 = ① 凸二次规划

② 拉格朗日乘子法 得 对偶问题

$$L(w, b, \alpha) = \frac{1}{2}\|w\|^2 + \sum_{i=1}^{m} \alpha_i (1 - y_i(w^T x_i + b))$$

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial b} = 0 \Rightarrow w = \sum_{i=1}^{m} \alpha_i y_i x_i$$

$$0 = \sum_{i=1}^{m} \alpha_i y_i$$

对偶问题 =

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$s.t.\ \sum_{i=1}^{m} \alpha_i y_i = 0,\ \alpha_i \geq 0.$$

得 $f(x) = w^T x + b = \sum_{i=1}^{m} \alpha_i y_i x_i^T x + b$ （b可以求出）

w和b只与"恰好在间隔上"的"支持向量"有关

支持向量 = $y_i f(x_i) = 1$，其余向量 $\alpha_i = 0$

SMO过程：

① 选择一对 α_i，α_j（样本点距离越大越好）

② 固定其他参数，重新计算 α_i 和 α_j

③ 判断是否收敛

④ $b = \frac{1}{|S|} \sum_{s \in S} \left(y_s^{-1} - \sum_{i \in S} \alpha_i y_i x_i^T x_s\right) = \overline{b}$

核函数

低维向高维映射 $\phi(x)$

核函数 $\kappa(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle = \phi(x_i)^T \phi(x_j)$

κ 是核函数 $\Leftrightarrow$ 对于任意数据 $D = \{x_1, \dots, x_m\}$，

核矩阵 K 总是半正定的

选择合适的核函数可以将向量积映射到高维且简化运算

表 6.1 常用核函数

名称	表达式	参数
线性核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j$	
多项式核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = (\boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j)^d$	$d \geqslant 1$ 为多项式的次数
高斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|}{\sigma}\right)$	$\sigma > 0$
Sigmoid 核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \tanh(\beta \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j + \theta)$	tanh 为双曲正切函数, $\beta > 0, \theta < 0$

核函数的线性组合，直积，$g(x)k(x,z)g(z)$ 也是核函数

软间隔

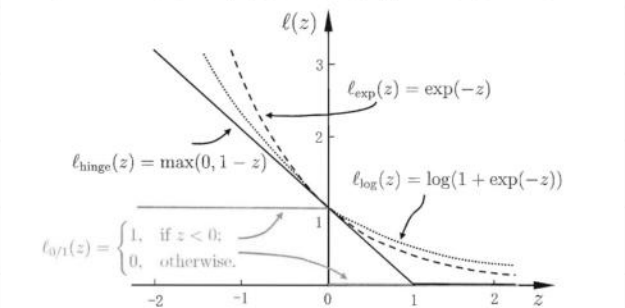
引入损失函数 $\ell_{0/1}(z) = \mathbb{I}(z < 0)$

优化目标 $= \min_{w,b} \frac{1}{2}\|w\| + C\sum_{i=1}^{m} \ell_{0/1}(y_i(w^T x_i + b) - 1)$

hinge 损失: $\ell_{hinge}(z) = \max(0, 1 - z)$; (6.31)

指数损失(exponential loss): $\ell_{exp}(z) = \exp(-z)$; (6.32)

对率损失(logistic loss): $\ell_{log}(z) = \log(1 + \exp(-z))$. (6.33)



得到新对偶问题：

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$s.t. \sum_{i=1}^{m} \alpha_i y_i = 0, \quad 0 \le \alpha_i \le C$$

支持向量回归

取入 ϵ-不敏感损失函数 $\ell_\epsilon(z) = \max\{0, |z| - \epsilon\}$

优化目标 $= \min_{w,b} \frac{1}{2}\|w\| + C \sum_{i=1}^{m} \ell_\epsilon(f(x_i) - y_i)$

设软间隔，回归的松弛变量分别为 $\xi, \hat{\xi}$，

拉格朗日乘子 $\mu_i, \hat{\mu_i}, \alpha_i, \hat{\alpha_i}$

SVR解 $= f(x) = \sum_{i=1}^{m} (\hat{\alpha_i} - \alpha_i) x_i^T x + b$

α_i 和 $\hat{\alpha_i}$ 至少有一个为0

第7章. 贝叶斯分类器

误判损失 λ_{ij}，最小化样本条件风险 $\Rightarrow$ 最小化总体风险

当 $\lambda_{ij}=\mathbb{I}(i\neq j)$ 时，条件风险 $R(c|x)=1-P(c|x)$

$P(c|x)=P(c)P(x|c)/P(x)$

先验 $P(c)$ = 根据频率估计

似然 $P(x|c)$ = 极大似然估计（对数似然）

$$\hat{\mu}_c=\frac{1}{|D_c|}\sum_{x\in D_c}x$$

$$\hat{\sigma}_c^2=\frac{1}{|D_c|}\sum_{x\in D_c}(x-\hat{\mu}_c)(x-\hat{\mu}_c)^T$$

令 N 表示 D 中可能的类别数：

$$\hat{P}(c)=\frac{|D_c|+1}{|D|+N}\qquad \hat{P}(x_i|c)=\frac{|D_{c,x_i}|+1}{|D_c|+N_i}$$

半朴素贝叶斯

独依赖：每个属性在类别之外最多仅依赖于一个其他属性（父属性 pa_i）

$$P(c|x)\propto P(c)\prod_{i=1}^{d}P(x_i|c,pa_i)$$

超父（SPODE）：假设所有属性都依赖于同一个属性，交叉验证

TAN（基于最大带权生成树）

1. 条件互信息：$I(x_i,x_j|y)=\sum_{x_i,x_j;c\in y}P(x_i,x_j|c)\log\frac{P(x_i,x_j|c)}{P(x_i|c)P(x_j|c)}$

   刻画了属性在已知类别情况下的相关性

2. 构建属性为结点的完全图，边权 $I(x_i,x_j|y)$

3. 构建最大带权生成树，挑选根变量，设置有向边

   只保留最大权的边

4. 加入类别结点 y，增加从 y 到每个属性的多向边

贝叶斯网

有向分离：道德图、道德化：连接所有V结构，变为无向图

若道德图中去掉Z后x、y分属两个连通分支，则 $x \perp y | z$

最小描述长度MDL准则：

$$s(B|D) = f(\theta)|B| - LL(B|D)$$

$f(\theta)$：字节数 $|B|$：贝叶斯网参数个数

$LL(B|D)$：贝叶斯网对数似然 $\sum_{i=1}^{m} \log P_B(x_i)$

$AIC: f(\theta)=1$　　$BIC: f(\theta)=\frac{1}{2}\log m$

吉布斯采样

①随机产生 $E=e$ 一致的 q^0

②在第t次采样中，先假设 $q^t = q^{t-1}$，逐个采样非证据变量，再采样 q_i^t

经过T次采样，与q一致的样本n'个，则 $P(Q=q|E=e) \approx \frac{n'}{T}$

基于马尔可夫链，最终收敛于平稳分布 $P(Q|E=e)$

马尔可夫链：概率矩阵，概率转移矩阵 $\xrightarrow{多次}$ 稳定概率分布

蒙特卡罗方法：取样估计，$\theta = \int_a^b f(x)dx = \int_a^b \frac{f(x)}{P(x)} P(x)dx \approx \frac{1}{n}\sum \frac{f(x_i)}{P(x_i)}$

如果得到比较的概率分布 $P(x)$ 则可直接采样（随机数生成器）

如果不能得到 $P(x)$ 则要使用接受-拒绝采样：

设定一个常用概率分布函数 $q(x)$，常量 k，使 $p(x) \le kq(x)$

对样本 x_0，使用 $kq(x_0)$ 采样得到 u，若 $u > p(x_0)$ 则拒绝

EM算法（基于马尔可夫过程的非递推优化算法）

X表示已观测变量集，Z表示隐变量集，Θ表示参数

极大对数似然估计 $= LL(\Theta|X,Z) = \ln P(X,Z|\Theta)$

通过对Z计算期望最大化边际似然

$LL(\Theta|X) = \ln P(X|\Theta) = \ln \sum_Z P(X,Z|\Theta)$

E步 $= \Theta^t \rightarrow Z^t = E(Z)$ | $\Theta^t \rightarrow P(Z|X,\Theta^t) \rightarrow E(Z)$

M步 $= Z^t, X \rightarrow \Theta^{t+1}$ | $\Theta^{t+1} = \arg\max_\Theta E(Z)$

隐变量Z举例 = 样本的来源、分类

A、B两个硬币，现不知道每次实验使用哪枚硬币，得到样本，

估计A、B硬币得到正面的概率 =

① 假设Θ_A, Θ_B，对每一轮求 $P(Z|X_i,\Theta_A)$ $P(Z|X_i,\Theta_B)$

乘x_i后得 $E(Z|X_i,\Theta_A)$、$E(Z|X_i,\Theta_B)$

② 使用极大似然估计 $= \Theta_A = \frac{E(Z_1|X_i,\Theta_A)}{E(Z|X_i,\Theta_A)}$，$\Theta_B = \frac{E(Z_1|X_i,\Theta_B)}{E(Z|X_i,\Theta_B)}$

反复迭代直到稳定收敛

证明：设Z的分布为$Q_i(Z)$，样本i隐含Z的某种分布

对数似然函数 $L(\Theta) = \sum_{i=1}^n \log P(X_i;\Theta) = \sum_{i=1}^n \log \sum_Z P(X_i,Z;\Theta)$

$= \sum_1^n \log \sum_Z^Z Q_i(Z) \frac{P(X_i,Z;\Theta)}{Q_i(Z)} = \sum_{i=1}^n \log E(Z)$

$\geq \sum_1^n \sum_Z^Z Q_i(Z) \log \frac{P(X_i,Z;\Theta)}{Q_i(Z)}$（凹函数log，得到下界）

当固定X时，X为常数，$Q_i(Z) = \frac{P(X_i,Z;\Theta)}{P(X_i;\Theta)} = P(Z|X_i;\Theta) = C$

$\hat{\Theta} = \arg\max_\Theta \sum_1^n \sum_Z^Z Q_i(Z) \log \frac{P(X_i,Z;\Theta)}{Q_i(Z)} = \arg\max_\Theta \sum_1^n \sum_Z^Z P(Z|X,\Theta) \log P(X,Z|\Theta)$

$= \arg\max_\Theta E_{Z|X,\Theta}(\log P(X,Z|\Theta))$，之后就可以求Z，求$\Theta$重复

第8章 集成学习

多分类器系统，基于委员会的学习，"好而不同"=准确性+多样性

Boosting 强依赖关系，必须串行

AdaBoost：主要降低偏差，可以基于泛化性能弱的基分类器，只用于二分类

加性模型：基学习器线性组合 $H(x)=\sum_{t=1}^{T}\alpha_t h_t(x)$

1. 初始化权重：每个样本权重相同，$D_1(x)=\frac{1}{m}$
2. 训练弱分类器：$h_t=\mathfrak{L}(D,b_t)$

学习误差率 $\epsilon_t=P_{x\sim D_t}(h_t(x)\neq f(x))$

学习器权重系数 $\alpha_t=\frac{1}{2}\ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$

样本权重 $D_{t+1}(x)=\frac{D_t(x)}{Z_t}\cdot\begin{cases}e^{-\alpha_t} & h_t(x)=f(x)\\ e^{\alpha_t} & h_t(x)\neq f(x)\end{cases}$

↳ 如果样本分类正确，则在下一个训练集中，其权值会降低，反之会提高

合成强分类器，加大误差率小的弱分类器权重，降低误差率大的弱分类器的权重

3. 得到强分类器 $H(x)=\mathrm{sign}\left(\sum_{t=1}^{T}\alpha_t h_t(x)\right)$

Bagging 基于自助采样法，高效集成，多分类/回归

采样出T个含m个训练样本的采样集，分别训练基学习器，再进行结合

分类=简单投票法　回归=简单平均法

降低方差，抗扰动

随机森林：在以决策树为基的Bagging集成上引入随机选择

从结点的属性集合中随机选择k个，再择优（$k=\log_2 d$）

多样性度量 比较两个分类器

不合度量：$dis_{ij} = \frac{b+c}{m}$

相关系数：$\rho_{ij} = (ad-bc) / ((a+b)(a+c)(d+b)(d+c))^{\frac{1}{2}}$

Q统计量（弱的相关系数）：$Q_{ij} = \frac{ad-bc}{ad+bc}$ $|Q_{ij}| \leq |\rho_{ij}|$

K-统计量：$K = \frac{P_1 - P_2}{1-P_2}$ 偶然 0 ⟶ 1 一致

$P_1 = \frac{a+d}{m}$ 取得一致的概率

$P_2 = ((a+b)(a+c)+(c+b)(d+c))/m^2$ 偶然一致的概率

样本扰动、输入属性扰动、输出表示扰动、算法参数扰动

第9章 聚类（自动分类得到标签）

性能度量

簇内相似度高，簇间相似度低；"外部指标"、"内部指标"

D → 聚类簇 C　对两个向量 x_i, x_j，有 $|SS|$、$|SD|$、$|DS|$、$|DD|$（a、b、c、d）

↘ 参考簇 C^*　S：在同一簇　D：在不同簇　共 C_m^2 个

Jaccard Coefficient：$JC = \frac{a}{a+b+c}$（1：一致/可能一致）

Fowlkes & Mallows Index：$FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$

Rand Index：$RI = \frac{a+d}{C_m^2} = \frac{2(a+d)}{m(m-1)}$

$avg(C)$：样本内平均距离 $= \sum_{1 \le i < j \le |C|} dist(x_i, x_j) / C_{|C|}^2$

$diam(C)$：样本内最大距离 $= \max_{1 \le i < j \le |C|} dist(x_i, x_j)$

$d_{min}(C_i, C_j)$：两样本间最小距离 $= \min_{x_i \in C_i, x_j \in C_j} dist(x_i, x_j)$

$d_{cen}(C_i, C_j)$：样本中心距离 $= dist(\mu_1, \mu_2)$

Davies-Bouldin Index：$DBI = \frac{1}{k} \sum_{i=1}^{k} \max_{j \ne i} \left(\frac{avg(C_i) + avg(C_j)}{d_{cen}(\mu_i, \mu_j)} \right)$

Dunn Index：$DI = \min_{1 \le i \le k} \left\{ \min_{j \ne i} \left(\frac{d_{min}(C_i, C_j)}{\max_{1 \le l \le k} diam(C_l)} \right) \right\}$

有序属性：闵可夫斯基距离：$dist(x_i, x_j) = \left(\sum_{u=1}^{n} |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}$

无序属性：VDM：$dist(a, b) = \sum_{i=1}^{k} \left| \frac{m_{u,a,i}}{m_{u,a}} - \frac{m_{u,b,i}}{m_{u,b}} \right|^p$

非度量距离：不满足直递性，但有利于分类

原型聚类

K-means $E=\sum_{i=1}^{k}\sum_{x\in C_i}\|x-\mu_i\|_2^2$ 簇内相似度最高的分类方法

① 输入分类簇数 k，从D中随机选择k个样本作为初始均值向量

② 计算所有点与中心向量的距离并分类，没变化则输出分类

③ 计算新的中心向量，转②，

学习向量量化 LVQ 样本本身带有类别标记，假设原型向量

每一轮迭代中，算法随机选取样本，判断与其最近的原型向量

基于标签判断是否在同一类，基于学习率调整原型向量

高斯混合聚类 使用概率模型

高斯混合分布 $P_M(x)=\sum_{i=1}^{k}\alpha_i\cdot p(x|\mu_i,\Sigma_i)$

$$p(x|\mu,\Sigma)=\frac{1}{(2\pi)^{\frac{n}{2}}|\Sigma|^{\frac{1}{2}}}\cdot e^{-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)}$$

结合EM算法：先验 $\rightleftarrows$ 后验

E：$(\alpha_i,\mu_i,\Sigma_i)\rightarrow\gamma_{ji}=P_M(z_j=i|x_j)=\frac{\alpha_i\,p(x_j|\mu_i,\Sigma_i)}{\sum_{l=1}^{k}\alpha_l\,p(x_j|\mu_l,\Sigma_l)}$

M：$\mu_i=\frac{\sum_{j=1}^{m}\gamma_{ji}x_j}{\sum_{j=1}^{m}\gamma_{ji}}$ $\Sigma_i=\frac{\sum_{j=1}^{m}\gamma_{ji}(x_j-\mu_i)(x_j-\mu_i)^T}{\sum_{j=1}^{m}\gamma_{ji}}$

$\lambda_j=\arg\max_i\gamma_{ji}$ $\alpha_i=\frac{1}{m}\sum_{j=1}^{m}\gamma_{ji}$ (m是簇内个数)

密度聚类

邻域、核心对象、密度直达（核心对象对邻域内对象）

密度可达（起点是核心对象），密度相连（起点可以不是）

簇：簇内所有元素相连，所有可达元素均在

过程= ①确定样本邻域，得到核心对象，放入队列

②随机选择核心对象，找到所有密度可达样本，生成簇

③去掉队列中的簇内核心对象，回到②

层次聚类

将样本看成聚类，逐步合并，直至合并到目标簇数

第10章、降维与度量学习

K-近邻学习 = 最近的k个邻居，投票法、平均法

低维嵌入 = 高维→低维，大致保持距离

多维缩放 = 输入距离矩阵 $D \in \mathbb{R}^{m \times m}$，

① 计算 = $dist_{i\cdot}^2$ = 从i出发到其他样本的距离的平均

$dist_{\cdot j}^2$ = 从其他样本出发到j的距离的平均

$dist_{\cdot\cdot}^2$ = 所有样本间距离的平均 $\frac{1}{m^2}\sum_{i=1}^{m}\sum_{j=1}^{m} dist_{ij}^2$

则回降维之后的内积矩阵B中元素 b_{ij} =

$dist_{ij}^2 = \|z_i\|^2 + \|z_j\|^2 - 2z_i^T z_j = b_{ii} + b_{jj} - 2b_{ij}$

得 $b_{ij} = -\frac{1}{2}(dist_{ij}^2 - dist_{i\cdot}^2 - dist_{\cdot j}^2 + dist_{\cdot\cdot}^2)$

② 降维 = 特征值分解 $B = V\Lambda V^T = Z^T Z$，

则降维向量 $Z = \Lambda^{\frac{1}{2}} V^T$

主成分分析 PCA =

最近重构性、最大可分性 $\Rightarrow \max_{s.t.\ W^TW=I} tr(W^T XX^T W)$

① 对所有样本去中心化 = $x_i \leftarrow x_i - \frac{1}{m}\sum x_i$

② 计算样本的协方差矩阵 XX^T

③ 特征分解 XX^T

④ 得到最大的d个特征值对应的特征向量，构成投影矩阵

核主成分分析 KPCA = 非线性降维

样本点 x_i 在高维空间的像 $z_i = \phi(x_i)$

KPCA = 先将 x_i 投影到高维，再将 z_i 使用PCA降维

新样本x的j维坐标为 $z_j = \sum_{i=1}^{m} \alpha_i^j \kappa(x_i, x)$，$\alpha_i^j = \frac{1}{\lambda_j} z_i^T w$

等度量映射：流形局部上与欧氏空间同胚，构造每个点的近邻点，建立一个近邻连接图，转化为路径问题

局部线性嵌入：通过保持邻域向量线性组合关系映射

线性关系：$\min_{w_1 \cdots w_m} \sum_{i=1}^{m} \| x_i - \sum_{j \in Q_i} w_{ij} x_j \|_2^2$

$s.t. \sum_{j \in Q_i} w_{ij} = 1$

则 w_{ij} 有闭式解：$w_{ij} = \frac{\sum_{k \in Q_i} C_{jk}^{-1}}{\sum_{l,s \in Q_i} C_{ls}^{-1}}$，$C_{jk} = (x_i - x_j)^T (x_i - x_k)$

低维中 w_i 不变，x_i 在低维的坐标 z_i 通过下式求解：

$$\min_{z_1 \cdots z_m} \sum_{i=1}^{m} \| z_i - \sum_{j \in Q_i} w_{ij} z_j \|_2^2$$

使用特征值分解求解：

$Z = (z_1, \cdots z_m)$　　$M = (I - W)^T (I - W)$

则原式 $= \min_Z tr(ZMZ^T)$　$s.t. ZZ^T = I$

度量学习　学习出合适的距离度量方法

d维样本的平方欧氏距离：$dist_{ed}^2(x_i, x_j) = \| x_i - x_j \|_2^2$

$= dist_{ij,1}^2 + \cdots + dist_{ij,d}^2$

加权平方欧氏距离：$dist_{wed}^2(x_i, x_j) = (x_i - x_j)^T W (x_i - x_j)$

马氏距离：$dist_{mah}^2(x_i, x_j) = (x_i - x_j)^T M (x_i - x_j) = \| x_i - x_j \|_M^2$

M是半正定对称矩阵，表示非正交（线性）的特征，$M = PP^T$

使用留一法，优化目标为：

$$\min_P 1 - \sum_{i=1}^{m} \sum_{j \in \Omega_i} \frac{e^{-\| P^T x_i - P^T x_j \|_2^2}}{\sum_l e^{-\| P^T x_i - P^T x_l \|_2^2}}$$

第11章. 特征选择与稀疏学习

过滤式选择：Relief (Relevant Features)

猜中近邻：$x_{i,nh}$　　猜错近邻：$x_{i,nm}$

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \text{diff}(x_i^j, x_{i,nm}^j)^2$$

机器学习实践：麻将AI超参学习

方法：贝叶斯优化 Bayesian Optimization 的超参数学习

对比 grid / ramdom / bayesian：grid 范围小，ramdom 开销大（后验）

bayesian 是 informed（先验）

用于：相对均匀，相对平滑，不可微的复杂函数的拟合

BO 的标准过程：SMBO

SMBO（函数 f，M_0，T，代理 S）S 是对 f 的近似

$H \leftarrow \emptyset$ History $\{x, f(x)\}$，对 H 进行建模得到分布 M

For $t \leftarrow 1$ to T：

$x^* \leftarrow \text{argmin}_x S(x, M_{t-1})$ 使代理 S 最小的参数 x

Evaluate $f(x^*)$

$H \leftarrow H \cup (x^*, f(x^*))$

Fit a new model M_t to H.

不同的 BO：
① 概率模型如何建模
② S 如何选，如何 evaluate

return H

② 刻画 Acquisition function：

可能出现的情况：

Exploitation：在目前最优周围找

Exploration：探索更多可能边界

Expected Improvement：

$$EI_{y^*}(x) = \int_{-\infty}^{+\infty} \max(y^* - y, 0) P_M(y|x) dy$$

表示对于一个给定 x 的值 y 相对阈值 y^* 提升了多少期望

$x_{new} = \text{argmax}_x EI_{y^*}(x)$ = 选择均值小、方差大的区域

① 如何进行建模：高斯过程回归 GPR，

Tree Parzen Estimator TPE

1、GPR：纯粹的数学推理，只用到数学特征

没有观测点时，认为 y 服从一个无限维的高斯分布（x无限种）

高斯分布：$f(x)=\frac{1}{\sqrt{2\pi}\,\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

特点：非参数、不直接拟合回归系数，通过对数据的协方差结构进行建模推断新的数据点，

GPR可以为每一个预测提供置信区间

数学定义：输入X，输出y，$(x_1,\dots,x_n)\to(y_1\dots y_n)$

假设 $f(x)$ 是由高斯过程 $GP(m(x),k(x,x'))$ 中抽取的

$m(x)$：均值函数 表示 $f(x)$ 的均值，一般 $m(x)=0$

$k(x,x')$：协方差函数（核函数）

核函数选择：

1、径向基函数（RBF）核：$k(x,x')=\sigma^2 e^{-\frac{\|x-x'\|^2}{2l^2}}$

σ^2 控制核函数的幅度，l 控制距离（平滑）

2、线性核：$k(x,x')=x^Tx'$

3、噪声核：$k(x,x')=\sigma_n^2\delta(x,x')$，

δ 对噪声进行建模，σ_n^2 是噪声的方差

1. 联合分布：

$$\begin{bmatrix} y \\ y_* \end{bmatrix} \sim N\left(0, \begin{bmatrix} K(X,X)+\sigma_n^2 I & K(X,X_*) \\ K(X_*,X) & K(X_*,X_*) \end{bmatrix}\right)$$

训练数据点之间　训练点与预测点之间　预测点之间

2. 条件分布：

$$y_* \mid X, y, X_* \sim N(\mu_*, \sigma_*^2)$$

均值 μ_* 是在 X_* 的预测值

$$\mu_* = K(X_*, X)[K(X,X)+\sigma_n^2 I]^{-1} y$$

方差 σ_*^2 描述预值不确定性

$$\sigma_*^2 = K(X_*,X_*) - K(X_*,X)[K(X,X)+\sigma_n^2 I]^{-1} K(X,X_*)$$

例：(1.0, 2.0)、(2.0, 2.5)、(3.0, 3.7)，预测 $y_* \mid X_* = 1.5$

① 选择RBF核，取超参 $\sigma=1.0$，$l=1.0$，$K(x,x') = e^{-\frac{\|x-x'\|^2}{2}}$

② 计算协方差矩阵

$$K(X,X) = \begin{bmatrix} K(1,1) & K(1,3) \\ \vdots & \vdots \\ K(3,1) & K(3,3) \end{bmatrix}$$

③ 计算协方差向量

$$K[X, X_*] = \begin{bmatrix} K(1,1.5) \\ K(2,1.5) \\ K(3,1.5) \end{bmatrix}^T = \begin{bmatrix} 0.8825 \\ 0.8825 \\ 0.3247 \end{bmatrix}^T$$

④ 计算自协方差 $K(1.5, 1.5) = 1$

⑤ 计算 μ_*：

$$\mu_* = K(X_*, X)\left[K(X,X)+\sigma_n^2 I\right]^{-1} y$$

$$= \begin{bmatrix} 0.8825 \\ 0.8825 \\ 0.3247 \end{bmatrix}^T \begin{bmatrix} 2.123 & -1.242 & 0.231 \\ -1.242 & 2.123 & -1.242 \\ 0.231 & -1.242 & 2.123 \end{bmatrix} \begin{bmatrix} 2.0 \\ 2.5 \\ 3.7 \end{bmatrix} = 2.87$$

⑤计算方差 $\sigma_{x_*}^2$

$$\sigma_{x_*}^2 = K(x_*, x_*) - K(x_*, X)[K(X, X) + \sigma_n^2 I]^{-1} K(X, x_*)$$

$$= 1 - \begin{bmatrix} 0.8825 \\ 0.8825 \\ 0.3507 \end{bmatrix}^T \begin{bmatrix} 2.123 & -1.242 & 0.231 \\ -1.242 & 2.123 & -1.242 \\ 0.231 & -1.242 & 2.123 \end{bmatrix} \begin{bmatrix} 0.8825 \\ 0.8825 \\ 0.3507 \end{bmatrix} \approx 0.18$$

⑥置信度区间（95%对应分位数1.96）

$$\mu_{x_*} \pm 1.96 \times \sqrt{\sigma_{x_*}^2} = 2.87 \pm 1.96 \times 0.424 \approx 2.87 \pm 0.831$$

2. TPR：

基于 $P(y|x)=\frac{P(x|y)P(y)}{P(x)}$

一般情况下 y^* 由分位数 γ 取得，满足 $P(y<y^*)=\gamma$

γ 在TPR中一般为0.15或0.25

划分 $P(x|y)=\begin{cases} l(x), & y<y^* \\ g(x), & y>y^* \end{cases}$

由EI↑的目标可以推得，$y<y^*$ 的样本比较好，$y>y^*$ 的样本比较差

得 $P(x)=\int_R P(x|y)P(y)dy=\gamma l(x)+(1-\gamma)g(x)$

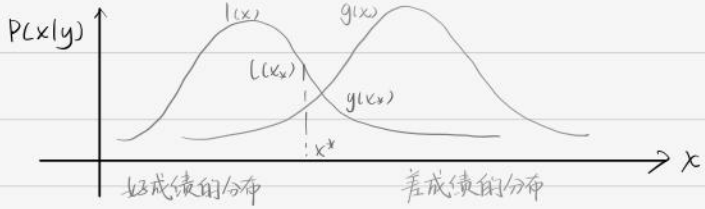
$$EI_{y^*}(x)=\int_{-\infty}^{+\infty}\max(y^*-y,0)P_M(y|x)dy$$

$$=\int_{-\infty}^{y^*}(y^*-y)P(y|x)dy$$

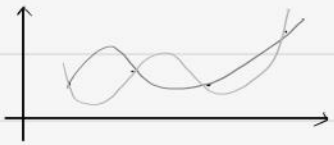
$l(x)\leftarrow \frac{P(x|y)P(y)}{P(x)\rightarrow \gamma l(x)+(1-\gamma)g(x)}$

$$=\frac{\int_{-\infty}^{y^*}(y^*-y)P(y)dy}{\gamma+(1-\gamma)g(x)/l(x)}$$

当 γ 确定之后，$g(x)/l(x)\downarrow$，$EI\uparrow$ → 找到 $\frac{P(x\text{属于成绩差})=P(y>y^*)}{P(x\text{属于成绩好})=P(y<y^*)}\downarrow$ 的 x



贝叶斯视角：



观测点同团，预测差异小

麻将策略中的参考常数

1. 基本数据：

	总牌山	手牌数	巡目	摸牌数
四麻	136	52	17~18	66~70
三麻	108	39	17~18	51~55

2. 基于几何分布算上牌期望。

四麻：

① 明确要的牌还有 x 张，场上还有 $39+y$ 张牌未知。

$P_1=10\% = \frac{5}{39+11} = \frac{6}{39+21} = \frac{7}{39+31} = \frac{8}{39+41} = \frac{9}{39+51} = \frac{10}{39+61}$

	还有 3巡	5巡	8巡	10巡	13巡	15巡
概率 $1-0.9^n$	27.1%	34.4%	57.0%	65.2%	74.6%	79.5%

$P_2=7.5\% = \frac{3}{39+1} = \frac{4}{39+14} = \frac{5}{39+27} = \frac{6}{39+40} = \frac{7}{39+53} = \frac{8}{39+67}$

	1巡	4巡	7巡	10巡	13巡	17巡
概率 $1-0.925^n$	7.5%	26.8%	42.1%	54.2%	63.7%	71.3%

$P_3=5\% = \frac{2}{39+1} = \frac{3}{39+21} = \frac{4}{39+41} = \frac{5}{39+61}$

	1巡	5巡	10巡	15巡
概率 $1-0.95^n$	5%	22.7%	40.2%	53.7%