概率总结

第1节：

1. 重要模型：等可能概率，几何概率
   "抽签原理"，小球放盒子
2. 条件概率：全概率公式，贝叶斯公式，独立性

第2节：

1. 分布函数
   - 离散型：
     - 伯努利实验：①0-1分布 ②二项分布 ③泊松分布 ④几何分布 ⑤帕斯卡分布
     - 古典概型：①超几何分布
   - 消条数法，折条数法，错项相减求和法，逐项积分求和法，公式对照法
   - 连续型：①均匀分布 ②指数分布 ③正态分布
     正态分布的再生性
2. 随机变量的函数：(分部函数法，公式法)

第3节：

1. 二维随机变量的分布函数 交换积分次序
2. 边缘分布和边缘密度 独立性 (分部函数法，公式法)，分布的可加性/再生性
3. 二维随机变量的期望与方差
4. 二维离散型随机变量 三项分布，二维超几何分布
5. 条件分布 条件分布的退化

第4节：

1. 数学期望的意义/性质 化简示性变量(伯努利变量)的求期望过程
2. 方差的定义和性质
3. 协方差
4. 相关系数
5. 切比雪夫不等式

第 1 节

1. 概率的三大性质：

(1) 非负性 (2) 规范性 (3) 可列可加性

2. 概率的重要模型：

(1) 等可能概型（古典概型）

样本空间中有有限个可能性相同的样本点

常见模型：

① 有放回抽取：

$$P=\frac{C_n^k M^k (N-M)^{n-k}}{N^n}=C_n^k \left(\frac{M}{N}\right)^k \left(1-\frac{M}{N}\right)^{n-k}$$

② 不放回抽取：

$$P=\frac{C_n^k C_{N-M}^{m-k}}{C_N^m}$$

"抽签原理"：$P(A)=\frac{b(a+b-1)!}{(a+b)!}=\frac{b}{a+b}$

N球放盒子：将n只小球随机放入以下N个盒子（$N\geq n$），

求以下概率：(1) 事件A：恰有n个盒子每盒1球 (2) 事件B：指定n个盒子每盒1球

先计算(2). 对于每个球，随机地放入N个盒子，共有N^n种可能

放入n个盒子且每个盒子恰有1球，有n!可能

故$P(B)=n!/N^n$

再计算(1)：从N个盒子里随机选取n个盒子

$$P(A)=C_N^n P(B)=\frac{C_N^n n!}{N^n}=\frac{N!}{N^n(N-n)!}$$

(2) 几何概率

样本空间有无限个等可能的样本点

常见模型：

(1) 明确样本空间 = 大多数的几何概率都可以将样本空间分解为若干个连续变量

布丰投针问题：平面上有等距离的平行线，平行线间的距离为a，向此平面投掷一枚长为l(l<a)的针，求针与任一平行线相交概率

设针的中点到最近平行线的距离为x，针的平行线夹角为θ，针的位置可以由(x, θ)决定

样本空间为$\Omega=\{(x,\theta)\mid 0\le x<\frac{a}{2},\ 0\le\theta<\pi\}$

若针与化一平行线相交，其充要条件为 $x \le \frac{1}{2}\sin\theta$

$A=\{(x,\theta) \mid 0 \le x \le \frac{1}{2}\sin\theta,\ 0 \le \theta \le \pi\}$

$\therefore P(A)=\frac{m(A)}{m(\Omega)}=\frac{\int_0^{\pi}\int_0^{\frac{1}{2}\sin\theta} dx\, d\theta}{a\pi/2}=\frac{2}{a\pi}$

3. 条件概率

$P(A|B)=\frac{P(AB)}{P(B)}$　　$P(AB)=P(A|B)P(B)$

"抽签原理" $=P(A_1\cdots A_{k-1}\bar{A}_k)=P(A_1)P(A_2|A_1)\cdots P(A_{k-1}|A_1\cdots A_{k-2})P(\bar{A}_k|A_1\cdots A_{k-1})$

$=\frac{n-1}{n}\cdot\frac{n-2}{n-1}\cdots\frac{n-(k-1)}{n-(k-2)}\cdot\frac{1}{n-(k-1)}=\frac{1}{n}$

全概率公式：$P(B)=\sum P(A_k)P(B|A_k)$

完备事件组　先验概率　后验概率

贝叶斯公式：$P(A_i|B)=\frac{P(A_i)P(B|A_i)}{\sum_{k=1}^{n}P(A_k)P(B|A_k)}$

独立：$P(AB)=P(A)P(B)$　　$P(A)=P(A|B)$

A与B独立，则 $\bar{A}$与B、$\bar{A}$与$\bar{B}$、A与$\bar{B}$也独立

多个事件的独立性：

以ABC三个事件为例，

ABC相互独立 $\Leftrightarrow$ $\begin{cases} P(AB)=P(A)P(B) \\ P(AC)=P(A)P(C) \\ P(BC)=P(B)P(C) \\ P(ABC)=P(A)P(B)P(C) \end{cases}$

需要满足A与BC独立，否则只能是两两独立

4. 独立重复试验概型：n重伯努利试验

（n次相互独立的古典概型有放回抽取）

(1) 二项分布：$P_n(k)=C_n^k p^k q^{n-k}$ $\sum_{0}^{k} P_n(i)=(p+q)^n=1$

(2) 泊松分布：$\lim_{n\to\infty} C_n^k p_n^k (1-p_n)^{n-k}=\frac{\lambda^k}{k!}e^{-\lambda}$ $(\lambda=np)$

用来拟合n足够大，p足够小的情况

伯努利试验特别强调"有放回"，而古典概型一般是"不放回"，对应的最基本也差距最大的两种分布为二项分布和超几何分布

第 2 节

随机变量的分布函数：

公式法：$F(x) = P(X \le x) = \int_{-\infty}^{x} p(x)dx$

↓ 分布函数　↓ 概率　↓ 密度函数

性质：(1) $F(x)$ 单调不减

(2) $0 \le F(x) \le 1$，$F(-\infty) = \lim_{x \to -\infty} F(x) = 0$　$F(+\infty) = \lim_{x \to +\infty} F(x) = 1$

(3) $F(x)$ 右连续　右连续原因：$F(x) = P(X \le x)$

如果是 $F(x) = P(X < x)$ 则是左连续

1. 离散型随机变量

伯努利实验：

① 0-1 分布

② 二项分布：多次独立重复的 0-1 分布

③ 泊松分布：n 足够大，p 足够小的二项分布，$\lambda = np$

$$P_k = P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

④ 几何分布：多次重复 0-1 分布，直到第 k 次得到目标结果

帕斯卡分布

（得名几何分布可能是因为默认 k 可以是无限）

古典概型

⑤ 超几何分布：$X \sim H(N, M, n)$，不放回抽取

伯努利实验

几何分布 = $X \sim g(p)$，$p_k = P(X=k) = q^{k-1}p$

无记忆性 = $P(X=s+t \mid X>t) = P(X=s)$ ⟩ 最后一次一定成功

帕斯卡分布 = $r=1$的帕斯卡分布退化为几何分布

定义1：成功概率为p，成功r次一共需做k次试验的概率，其分布列为

$$P(X=k) = C_{k-1}^{r-1}(1-p)^{k-r}p^r, \quad k \geq r$$

定义2：成功概率为p，成功第r次之前一共失败为k次的概率

$$P(X=k) = C_{k+r-1}^{r-1}(1-p)^k p^r, \quad k=0,1,2\ldots$$

二项分布的期望和方差

$$E(X) = \sum kP(X=k) = \sum k C_n^k p^k (1-p)^{n-k} = \sum n C_{n-1}^{k-1} p^k (1-p)^{n-k}$$ （指系数法）

$$= np\sum C_{n-1}^{k-1} p^{k-1}(1-p)^{n-k} = np$$

$$D(X) = E(X-E(X))^2 = E(X^2) - (EX)^2 = E(X^2) - n^2p^2$$

$$E(X^2) = \sum k^2 C_n^k p^k (1-p)^{n-k}$$ （指系数法）

处理$E(X^k)$的方法：

$$= \sum k(k-1) C_n^k p^k (1-p)^{n-k} + \sum k C_n^k p^k (1-p)^{n-k}$$

$$= \sum n(n-1) C_{n-2}^{k-2} p^{k-2}(1-p)^{n-k} p^2 + np$$

$$= n(n-1)p^2 + np - n^2p^2 = np(1-p) = npq$$

泊松分布的期望与方差

$$E(X) = \sum kP(X=k) = \sum_1^\infty k \frac{\lambda^k}{k!} e^{-\lambda} = \lambda \sum_1^\infty \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda} = \lambda \sum_0^\infty \frac{\lambda^k}{k!} e^{-\lambda} = \lambda$$

$$D(X) = E(X^2) - E^2(X)$$

$$= \sum k^2 \frac{\lambda^k}{k!} e^{-\lambda} - \lambda^2 = \sum k(k-1)\frac{\lambda^k}{k!}e^{-\lambda} + \sum k \frac{\lambda^k}{k!} e^{-\lambda} - \lambda^2$$

$$= \lambda^2 \sum \frac{\lambda^{k-2}}{(k-2)!} e^{-\lambda} + \lambda - \lambda^2 = \lambda$$

泊松分布中 $\lambda = np$，也就是说当 n 足够大，p 足够小时

$D(X) = npq = np(1-p) = np - np^2 = np$

几何分布的期望和方差

错项相减求和法：

$$E(X) = \sum_1^\infty k q^{k-1} p \quad \therefore qE(X) = \sum_1^\infty k q^k p$$

$$\therefore (1-q)E(X) = pE(X) = \sum_0^\infty q^k p = 1 \quad \therefore E(X) = \frac{1}{p}$$

逐项积分求和法

$$\frac{E(X)}{p} = \sum_1^\infty k q^{k-1} = \left(\sum_1^\infty q^k\right)'_q = \left(\frac{q(1-q^\infty)}{1-q}\right)_q = \left(\frac{q}{1-q}\right)_q = \frac{1}{(1-q)^2} = \frac{1}{p^2} \quad \therefore E(X) = \frac{1}{p}$$

直观解释：得到目标结果的可能为 p，所以期望 $\frac{1}{p}$ 次得到第 1 次目标结果

$$D(X) = E(X^2) - E^2(X) = \sum_1^\infty k^2 q^{k-1} p - \frac{1}{p^2}$$

错项相减求和法：错项相减求和法的关键是把系数降次

$$L = E(X^2) = \sum_1^\infty k^2 q^{k-1} p \quad \text{则 } qL = \sum_1^\infty k^2 q^k p$$

相减得 $pL = \sum_1^\infty (k^2 - (k-1)^2) q^{k-1} p = \sum_1^\infty (2k-1) q^{k-1} p = \sum_1^\infty 2k q^{k-1} p - \sum_1^\infty q^{k-1} p$

$$= \frac{2}{p} - \frac{p(1-q^\infty)}{1-q} = \frac{2}{p} - 1 \quad \therefore L = \frac{2-p}{p^2}$$

$$\therefore D(X) = \frac{1-p}{p^2} = \frac{q}{p^2}$$

逐项积分或和法

$$\frac{1}{p}=\sum k^2q^{k-1}=\sum k(q^k)'_q=(q\sum kq^{k-1})'_q=(\frac{q}{p^2})'_q=\frac{1+q}{p^3}$$

$$\therefore L=\frac{1+q}{p^2}\quad \therefore D(X)=E(X^2)-E^2(X)=\frac{1+q}{p^2}-\frac{1}{p^2}=\frac{q}{p^2}=\frac{1-p}{p^2}$$

$$q\sum kq^{k-1}=\frac{1}{p}q\sum kq^{k-1}p=\frac{1}{p}q\cdot\frac{1}{p}=\frac{q}{p^2}$$

巴斯卡分布的期望和方差（负二项分布中r是正整数的情况）

定义1：成功概率为p，成功r次一共需做k次试验的概率，其分布列为

$$P(X=k)=C_{k-1}^{r-1}(1-p)^{k-r}p^r,\ k\geq r$$

定义2：成功概率为p，成功第r次之前一共失败为k次的概率

$$P(X=k)=C_{k+r-1}^{r-1}(1-p)^k p^r,\ k=0,1,2\ldots$$

负二项分布得名

令 $f(x)=(1-x)^{-r}=\sum_0^\infty C_{-r}^k(-x)^k$

$$=\sum_0^\infty\frac{(-r)(-r-1)\cdots(-r-k+1)}{k!}(-1)^k x^k=\sum_0^\infty\frac{r(r+1)\cdots(r+k-1)}{k!}x^k=\sum_0^\infty\frac{(r+k-1)!}{k!(r-1)!}x^k$$

（k取负；定义2；定义1）

$$=\sum_0^\infty C_{r+k-1}^{r-1}x^k=\sum_r^\infty C_{k-1}^{r-1}x^{k-r}$$

$$\therefore f'(x)=r(1-x)^{-r-1}=\sum_0^\infty kC_{k+r-1}^{r-1}x^{k-1}=\sum_r^\infty(k-r)C_{k-1}^{r-1}x^{k-r-1}$$

$$f''(x)=r(r+1)(1-x)^{-r-2}=\sum_0^\infty k(k-1)C_{k+r-1}^{r-1}x^{k-2}=\sum_{k=r}^\infty(k-r)(k-r-1)C_{k-1}^{r-1}x^{k-r-2}$$

对于定义1：$E(X)=\sum_r^\infty kP(X=k)=\sum_r^\infty kC_{k-1}^{r-1}(1-p)^{k-r}p^r$

$$=p^r\left(\sum_r^\infty(k-r)C_{k-1}^{r-1}(1-p)^{k-r}+\sum_r^\infty rC_{k-1}^{r-1}(1-p)^{k-r}\right)$$

$$=p^r\left((1-p)f'(1-p)+rf(1-p)\right)=p^r\left(r(1-p)p^{-r-1}+rp^{-r}\right)=\frac{r}{p}$$

$r\cdot\frac{1}{p}$ 次测试的次数

$$E(X^2)=\sum_{k=r}^{\infty} kP(X=k)=\sum_{k=r}^{\infty} k^2 C_{k-1}^{r-1}(1-p)^{k-r}p^r$$

$$=p^r\left(\sum_{r}^{\infty}(k+r)(k-r-1)C_{k-1}^{r-1}(1-p)^{k-r}\right.$$

$$+(2r+1)\sum_{r}^{\infty}(k-r)C_{k-1}^{r-1}(1-p)^{k-r}$$

$$\left.+r^2\sum_{r}^{\infty}C_{k-1}^{r-1}(1-p)^{k-r}\right)$$

$$=p^r\left((1-p)^2f''(1-p)+(2r+1)(1-p)f'(1-p)+r^2f(1-p)\right)$$

$$=p^r\left((1-p)^2(r^2+r)p^{-r-2}+(2r+1)(1-p)rp^{-r-1}+r^2p^{-r}\right)$$

$$=\frac{r^2+r-rp}{p^2}$$

$$D(X)=E(X^2)-E^2(X)=\frac{r^2+r-rp}{p^2}-\frac{r^2}{p^2}=\frac{r(1-p)}{p^2}$$

对于定义2: $E(X)=\sum_{0}^{\infty}kP(X=k)=\sum_{0}^{\infty}kC_{r+k-1}^{r-1}(1-p)^kp^r$

$$=(1-p)p^rf'(1-p)=(1-p)p^r\cdot rp^{-r-1}=\frac{r(1-p)}{p}$$

两种定义的期望不同：$r\times\frac{1}{p}\times$ 失败的次数

$$E(X^2)=\sum_{0}^{\infty}k^2P(X=k)=\sum_{0}^{\infty}k^2C_{r+k-1}^{r-1}(1-p)^kp^r$$

$$=p^r\left(\sum_{0}^{\infty}k(k-1)C_{k+r-1}^{r-1}(1-p)^k+\sum_{0}^{\infty}kC_{k+r-1}^{r-1}(1-p)^k\right)$$

$$=p^r\left((1-p)^2f''(1-p)+(1-p)f'(1-p)\right)$$

$$=p^r\left((1-p)^2(r^2+r)p^{-r-2}+(1-p)rp^{-r-1}\right)$$

$$=\frac{r^2p^2-(2r^2+r)p+r^2+r}{p^2}$$

$$D(X)=E(X^2)-E^2(X)=\frac{r^2p^2-(2r^2+r)p+r^2+r}{p^2}-\frac{r^2(1-p)^2}{p^2}=\frac{r(1-p)}{p^2}$$

帕斯卡分布的方差和期望的数字意义都很直观，也可以用几何分布的无记忆性将其看成是n次几何分布的叠加

超几何分布的期望和方差

引理1：$kC_M^k = MC_{M-1}^{k-1}$ $\left(\frac{C_{M-1}^{k-1}}{C_M^k} = \frac{k}{M}\right)$

引理2：当 $n \le N-M$ 时，$\sum_{k=1}^{\min(M,n)} C_{M-1}^{k-1} C_{N-M}^{m-k} = C_{N-1}^{m-1}$

当 $n > N-M$ 时，$\sum_{k=n-N+M}^{\min(M,n)} C_{M-1}^{k-1} C_{N-M}^{m-k} = C_{N-1}^{m-1}$

引理证明：对于形如 $\sum C_A^x C_B^{C-x} = C_{A+B}^C$ 的式子均可使用恒等式

$(1+x)^A (1+x)^B = (1+x)^{A+B}$ 中 x^C 项的系数相等来证明

（也符合排素意义上的“取数”的理解）

$$E(X) = \sum kP(X=k) = \sum k \frac{C_M^k C_{N-M}^{n-k}}{C_N^n} = \sum \frac{MC_{M-1}^{k-1} C_{N-M}^{n-k}}{C_N^n}$$

$$= \frac{M}{C_N^n} \times C_{N-1}^{n-1} = \frac{nM}{N}$$

$$E(X^2) = \sum k^2 P(X=k) = \sum k^2 \frac{C_M^k C_{N-M}^{n-k}}{C_N^n} = \sum k(k-1) \frac{C_M^k C_{N-M}^{n-k}}{C_N^n} + \sum k \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}$$

$$= \sum \frac{M(M-1) C_{M-2}^{k-2} C_{N-M}^{n-k}}{C_N^n} + \frac{nM}{N} = \frac{M(M-1) C_{N-2}^{n-2}}{C_N^n} + \frac{nM}{N}$$

$$= \frac{M(M-1) n(n-1)}{N(N-1)} + \frac{nM}{N} = \frac{M(M-1)n(n-1) + nM(N-1)}{N(N-1)}$$

$$\therefore D(X) = E(X^2) - E^2(X) = \frac{M(M-1)n(n-1) + nM(N-1)}{N(N-1)} - \frac{n^2M^2}{N^2} = \frac{nM(N-n)(N-M)}{N^2(N-1)}$$

2. 连续型随机变量及其分布

① 均匀分布，$X \sim U[a,b]$

$$P(x)=\begin{cases}\frac{1}{b-a} & a<x<b\\ 0 & \text{其他}\end{cases} \qquad F(x)=\begin{cases}0 & x<a\\ \frac{x-a}{b-a} & a\le x<b\\ 1 & x\ge b\end{cases}$$

② 指数分布 $X \sim E(\lambda)$

$$P(x)=\begin{cases}\lambda e^{-\lambda x} & x\ge 0\\ 0 & x<0\end{cases} \qquad F(x)=\begin{cases}1-e^{-\lambda x} & x\ge 0\\ 0 & x<0\end{cases}$$

③ 正态分布 $X \sim N(\mu,\sigma^2)$

$$P(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}} \qquad -\infty<x<+\infty$$

标准正态分布 $= X \sim N(0,1)$，$P(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}$

在计算正态分布的变形形式的时候，可以采用以下技巧

① 配方凑正态分布形式 = 将 e 的指数凑成 $\frac{-1}{2\sigma^2}(x-\mu)^2+ax+b)$

② 若 $X \sim N(\mu,\sigma^2)$，则 $Z=\frac{X-\mu}{\sigma} \sim N(0,1)$　$X \sim \sigma N(0,1)+\mu$

③ 用正态分布性质积分 = $\int_{-\infty}^{+\infty}P(x)dx=1$ 或 $\int_{-\infty}^{x}P(x)dx=F(x)$

④ 若 $X \sim N(\mu_1,\sigma_1^2)$，$Y \sim N(\mu_2,\sigma_2^2)$，$X+Y \sim (\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$

卡方分布 χ^2 = 若 n 个相互独立的随机变量 $\xi_1,\xi_2,\dots\xi_n$ 均服从标准正态分布，

则 $\sum_1^k \xi_i^2 \sim \chi_k^2$

泊松积分 $= \int_0^{+\infty}e^{-ax^2}\cos bx\,dx=\frac{1}{2}\sqrt{\frac{\pi}{a}}e^{-\frac{b^2}{4a}}$

特别地，令 $a=1$，$b=0$ 可得 $\int_0^{+\infty}e^{-x^2}dx=\frac{1}{2}\sqrt{\pi}$，$\int_{-\infty}^{+\infty}e^{-x^2}dx=\sqrt{\pi}$

$$\int_{-\infty}^{+\infty} e^{-(ax^2-2bx+c^2)}\,dx = e^{\frac{ac-b^2}{a}}\sqrt{\frac{\pi}{a}}$$

正态分布的再生性

① 正态随机变量的线性组合仍为正态随机变量

若 $X\sim N(\mu_1,\sigma_1^2)$，$Y\sim N(\mu_2,\sigma_2^2)$，则 $X+Y\sim N(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$

独立随机变量相加减的现实意义：假设X表示第1次掷色子得到的结果，Y表示第2次掷色子得到的结果，则X+Y表示前两次掷色子共得多点，X-Y反应了第2次掷色子各样本点与第1次掷色子各样本点之间相减产生的差距对应的新的样本点的对应概率要用卷积公式计算

以Z=X+Y为例

$$\begin{aligned}
P_Z(x) &= \int_{-\infty}^{+\infty} P_1(x)P_2(z-x)\,dx \\
&= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma_1} e^{\frac{-(x-\mu_1)^2}{2\sigma_1^2}} \frac{1}{\sqrt{2\pi}\sigma_2} e^{\frac{-[z-x-\mu_2)]^2}{2\sigma_2^2}}\,dx \\
&= \int_{-\infty}^{+\infty} \frac{1}{2\pi\sigma_1\sigma_2} e^{\frac{-(x-\mu_1)^2}{2\sigma_1^2}+\frac{-(z-x-\mu_2)^2}{2\sigma_2^2}}\,dx \\
&= \int_{-\infty}^{+\infty} \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{1}{2}\left(\frac{1}{\sigma_1^2}(x-\mu_1)^2+\frac{1}{\sigma_2^2}(z-x-\mu_2)^2\right)}\,dx \\
&= \int_{-\infty}^{+\infty} \frac{1}{2\pi\sigma_1\sigma_2} e^{-(ax^2-2bx+c^2)}\,dx
\end{aligned}$$

其中 $a=\frac{1}{2}\left(\frac{1}{\sigma_1^2}+\frac{1}{\sigma_2^2}\right)$，$b=\frac{1}{2}\left(\frac{\mu_1}{\sigma_1^2}+\frac{z-\mu_2}{\sigma_2^2}\right)$，$c=\frac{1}{2}\left(\frac{\mu_1^2}{\sigma_1^2}+\frac{(z-\mu_2)^2}{\sigma_2^2}\right)$

得 $P_Z(x)=\frac{1}{\sqrt{2\pi(\sigma_1^2+\sigma_2^2)}} e^{\frac{-[z-(\mu_1+\mu_2)]^2}{2(\sigma_1^2+\sigma_2^2)}}$ ∴ $Z\sim N(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$

特别地，当 $N_2\sim N(0,\sigma_2^2)$ 时，也就是当 μ_2 为零均值的高斯白噪声时，$f(x+\mu_1)=f(x-y)$

即在一个独立分布上加减一个白噪声，其为同分布

② 正态变量的线性函数仍为正态变量

若 $X \sim N(\mu, \sigma^2)$，$Y = AX + B$，则 $Y \sim N(A\mu + B, A^2\sigma^2)$

推导 $Y = g(X) = AX + B$ 单调 $g^{-1}(x) = \frac{x-B}{A}$ $g^{-1}(x)' = \frac{1}{A}$

$$P_Y(y) = P_X(g^{-1}(x))\, g^{-1}(x)' = \frac{1}{A}\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\frac{x-B}{A}-\mu)^2}{2\sigma^2}}$$

$$= \frac{1}{\sqrt{2\pi}A\sigma} e^{-\frac{(x-B-A\mu)^2}{2A^2\sigma^2}}$$

故 $Y \sim N(B + A\mu, A^2\sigma^2)$

③ 正态随机变量的乘积仍为正态随机变量（和卡方分布有所区别）

若 $X \sim N(\mu_1, \sigma_1^2)$，$X$ 的密度函数是 $P_X(x)$，$Y \sim N(\mu_2, \sigma_2^2)$，$Y$ 的密度函数是 $P_Y(y)$，则若 Z 的密度函数是 $P_Z(z) = P_X(z)P_Y(z)$，则 $Z \sim N\left(\frac{\mu_2\sigma_1^2 + \mu_1\sigma_2^2}{\sigma_1^2+\sigma_2^2}, \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2}\right)$

推导 $P_Z(z) = P_X(z)P_Y(z) = \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2} - \frac{(x-\mu_2)^2}{2\sigma_2^2}} = \frac{1}{2\pi\sigma_1\sigma_2} e^{-\left(\frac{(x-\mu_1)^2\sigma_2^2 + (x-\mu_2)^2\sigma_1^2}{2\sigma_1^2\sigma_2^2}\right)}$

$$= \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{\left(x - \frac{\mu_1\sigma_2^2 + \mu_2\sigma_1^2}{\sigma_1^2+\sigma_2^2}\right)^2}{\frac{2\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2}} - \frac{(\mu_1-\mu_2)^2}{2\sigma_1^2\sigma_2^2}}$$

$$= \frac{e^{-\frac{(\mu_1-\mu_2)^2}{2\sigma_1^2+2\sigma_2^2}}}{\sqrt{2\pi(\sigma_1^2+\sigma_2^2)}} \cdot \frac{1}{\sqrt{2\pi}\frac{\sigma_1\sigma_2}{\sqrt{\sigma_1^2+\sigma_2^2}}} e^{\frac{\left(x - \frac{\mu_2\sigma_1^2 + \mu_1\sigma_2^2}{\sigma_1^2+\sigma_2^2}\right)^2}{\frac{2\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2}}}$$

卷积：$Z = X \cdot Y$，求 P_Z（卡方分布）

乘积：$Z = (X, Y)$，X 和 Y 相互独立，求 P_Z

④ 瑞利分布 X, Y 独立同分布 $N(0,1)$，$Z=\sqrt{X^2+Y^2}$，Z 服从瑞利分布

(X,Y) 有联合密度 $f(x,y)=\frac{1}{2\pi}e^{-\frac{x^2+y^2}{2}}$

$F_Z=P(\sqrt{X^2+Y^2}\le z)=\iint_{\sqrt{x^2+y^2}\le z}\frac{1}{2\pi}e^{-\frac{x^2+y^2}{2}}dxdy$

化为极坐标 $x=r\cos\theta$ $y=r\sin\theta$

$F_Z=\int_0^{2\pi}\int_0^z\frac{1}{2\pi}e^{-\frac{r^2}{2}}drd\theta=\int_0^z e^{-\frac{r^2}{2}}dr$

则 $f_Z(z)=ze^{-\frac{z^2}{2}}$，$z\ge 0$

四连续型随机变量

均匀分布、指数分布、正态分布

① 均匀分布 $\begin{cases} P(x)=\begin{cases}\frac{1}{b-a} & a\le x\le b\\ 0 & \text{其他}\end{cases} \\ E(x)=\frac{1}{2}(a+b) \\ D(x)=\frac{1}{12}(b-a)^2\end{cases}$ $F(x)=\begin{cases}1 & x\ge b\\ \frac{x-a}{b-a} & a\le x<b\\ 0 & x<a\end{cases}$

② 指数分布 $\begin{cases} P(x)=\begin{cases}\lambda e^{-\lambda x} & x>0\\ 0 & \text{其他}\end{cases} \\ E(x)=\lambda^{-1} \\ D(x)=\lambda^{-2}\end{cases}$ $F(x)=\begin{cases}1-e^{-\lambda x} & x>0\\ 0 & x\le 0\end{cases}$

> 分部积分法

$$\int_0^{+\infty} x\lambda e^{-\lambda x}dx=\int_0^{+\infty}-x\,de^{-\lambda x}=-xe^{-\lambda x}\Big|_0^{+\infty}-\int_0^{+\infty}e^{-\lambda x}d(-x)=\lambda^{-1}$$

3. 连续型随机变量的函数

设X是连续型随机变量，$y=g(x)$是连续实函数，则$Y=g(X)$也是连续型随机变量。已知X的密度函数$p_X(x)$，求Y的密度函数$p_Y(y)$

这要求$g(x)$连续，密度函数只有连续时积分函数的导数，调节有限/可列个点的密度函数的值将不影响分布函数。当密度函数的分母为0时要调整这个点的密度函数值（一般调成方闭右开 $<,\leq$）

方法1 = 分布函数法（定义法）

$$F_Y(y)=P(Y\leq y)=P(g(X)\leq y)=\int_{x:g(x)\leq y} p_X(x)\,dx$$

$$p_Y(y)=F_Y'(y)$$

要严格分析$g(x)$的定义域（X的取值范围）和值域（y的取值范围）

方法2 = 公式法

要求$y=g(x)$要严格单调，对应最简单的分布函数

$$p_Y(y)=\begin{cases} p_X[g^{-1}(y)]\cdot[g^{-1}(y)]'_y, & \alpha<y<\beta \quad (y\text{的理论取值范围}) \\ 0, & \text{其他} \end{cases}$$

第三章

1. 二维随机变量的分布函数

$F(x,y)=P(X\le x, Y\le y)$

离散型 $F(x,y)=\sum_{x_i\le x}\sum_{y_j\le y}p_{ij}$ ☆交换积分次序

连续型 $F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}p(u,v)\,du\,dv$

二维随机变量的刻画：

① 无论何种情况都可以使用定义法刻画 $F(x,y)$，将样本空间（xOy平面）分区之后用分布函数表示

② 当X和Y相互独立的时候，才能用边缘密度的乘积表示

2. 边缘分布和边缘密度

$F_X(x)=P(X\le x)=P(X\le x, Y\le+\infty)=F(x,+\infty)=\lim_{y\to+\infty}F(x,y)$

$F_Y(y)=P(Y\le y)=P(X\le+\infty, Y\le y)=F(+\infty,y)=\lim_{x\to+\infty}F(x,y)$

若随机事件 $X\le x$ 与 $Y\le y$ 独立，则

$P(X\le x, Y\le y)=P(X\le x)P(Y\le y)$，即 $F(x,y)=F_X(x)F_Y(y)$

同时有 $P(x,y)=P_X(x)P_Y(y)$

二维随机变量的值是根据实验事实得到的，边缘分布的意义是在二维变量所描述的实验里某一变量的分布，和另一个变量严格无关，边缘分布可以用来判定两个分布的相关性，也可以在描述同一种实验的情况下，调整两种边缘分布的形式，得到原来两边缘分布 X、Y 的函数的分布

3. 二维随机变量的期望与方差

$$E(X)=\sum_i\sum_j x_i p_{ij}=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}x\,P(x,y)\,dxdy=\int_{-\infty}^{+\infty}x P_X(x)\,dx$$

$$E(Y)=\sum_i\sum_j y_i p_{ji}=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}y\,P(x,y)\,dxdy=\int_{-\infty}^{+\infty}y P_Y(y)\,dy$$

1. 二维随机变量的期望

对于二维随机变量(X,Y)，若$E(X)$，$E(Y)$存在，则称$(E(X),E(Y))$为其期望

2. 二维随机变量函数的期望

若$Z=g(X,Y)$，则Z的数学期望$E(Z)$得

$$E(Z)=E(g(X,Y))=\sum_i\sum_j g(x_i,y_i)p_{ij}$$

$$=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}g(x,y)P(x,y)\,dxdy$$

3. 二维随机变量函数的方差

$$D(X)=E(X-E(X))^2=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}(x-E(x))^2P(x,y)\,dxdy$$

$$=\int_{-\infty}^{+\infty}(x-E(x))^2P_X(x)\,dx$$

$$D(y)=E(y-E(y))^2=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}(y-E(y))^2P(x,y)\,dxdy$$

$$=\int_{-\infty}^{+\infty}(y-E(y))^2P_Y(y)\,dy$$

4. 二维离散型随机变量

① 三项分布 (三项分布的边缘分布是二项分布)

$$P(X=i, Y=j) = C_n^i C_{n-i}^j p_1^i p_2^j (1-p_1-p_2)^{n-i-j}$$

(n次重伯努利试验中, 若每次试验有三种结果 A_1, A_2, A_3) 有放回

求三项分布的边缘分布 = 若 $(X, Y) \sim T(n, p_1, p_2)$

则 $P(X=k) = \sum_0^{n-k} P(X=k, Y=j) = \sum_0^{n-k} C_n^k C_{n-k}^j p_1^k p_2^j (1-p_1-p_2)^{n-k-j}$

$= C_n^k p_1^k \sum_0^{n-k} C_{n-k}^j p_2^j (1-p_1-p_2)^{n-k-j}$

$= C_n^k p_1^k (1-p_1)^{n-k}$

② 二维超几何分布 (二维超几何分布的边缘分布是超几何分布)

$$P(X=n_1, Y=n_2) = \frac{C_{N_1}^{n_1} C_{N_2}^{n_2} C_{N-N_1-N_2}^{n-n_1-n_2}}{C_N^n}$$

不放回

二维超几何分布的边缘分布

$$P(X=k) = \sum_0^{n-k} P(X=k, Y=j) = \sum_0^{n-k} \frac{C_{N_1}^k C_{N_2}^j C_{N-N_1-N_2}^{n-k-j}}{C_N^n}$$

$$= \frac{C_{N_1}^k C_{N-N_1}^{n-k}}{C_N^n}$$

5. 离散型二维变量函数的分布（这里以 $Z=X+Y$ 为例）

$$P_Z(z)=\sum_{0}^{z}P(X=k,Y=z-k)\overset{独立}{=}\sum_{0}^{z}P_X(X=k)P_Y(Y=z-k)$$

☆ 分布的可加性/再生性

（本质是 $P(x)P(y)=P(x+y)$，本质是 $F(x)F(y)=F(x+y)$）

① 泊松分布可加性：

$X\sim\pi(\lambda_1)$，$Y\sim\pi(\lambda_2)$，X,Y 相独立 $\Rightarrow X+Y\sim\pi(\lambda_1+\lambda_2)$

证明：$P_X(x)=\frac{\lambda^x e^{-\lambda}}{x!}$　$P_Y(y)=\frac{\lambda^y e^{-\lambda}}{y!}$

$$P_Z(z)=\sum_{0}^{z}P(X=k,Y=z-k)=\sum_{0}^{z}\frac{\lambda_1^k e^{-\lambda_1}}{k!}\cdot\frac{\lambda_2^{z-k}e^{-\lambda_2}}{(z-k)!}$$

$$=\frac{e^{-(\lambda_1+\lambda_2)}}{z!}\sum_{0}^{z}C_z^k\lambda_1^k\lambda_2^{z-k}=\frac{e^{-(\lambda_1+\lambda_2)}}{z!}(\lambda_1+\lambda_2)^z$$

② 二项分布可加性：

$X\sim b(n_1,p)$，$Y\sim b(n_2,p)$，X,Y 相互独立 $\Rightarrow X+Y\sim b(n_1+n_2,p)$

证明：$P_X(x)=C_{n_1}^x p^x(1-p)^{n_1-x}$　$P_Y(y)=C_{n_2}^y p^y(1-p)^{n_2-y}$

$$P_Z(z)=\sum_{0}^{z}P_X(k)P_Y(z-k)=\sum_{0}^{z}C_{n_1}^k p^k(1-p)^{n_1-k}C_{n_2}^{z-k}p^{z-k}(1-p)^{n_2-z+k}$$

$$=\sum_{0}^{z}C_{n_1}^k C_{n_2}^{z-k}p^z(1-p)^{n_1+n_2-z}=C_{n_1+n_2}^z p^z(1-p)^{n_1+n_2-z}$$

③ 正态分布的可加性（不是离散型随机变量）

见前面

6. 连续型二维变量函数的分布

设 $Z=g(X,Y)$，求 Z 的密度函数

方法1：分部函数法（定义法）

$$F_Z(z)=P(Z\le z)=P(g(X,Y)\le z)=\iint_{g(x,y)\le z} p(x,y)\,dxdy$$

$$p_Z(z)=F_Z'(z)$$

（有时候 $F_Z(z)$ 积不出来，可以直接求导表示）

方法2：公式法

设一个二维变量 $u=g(x,y)$，另一个二维变量 $v=h(x,y)$，使这两个变量也能刻画 x,y 所描述的实验，则可以求出 U 和 V 的联合分布律 $F_{u,v}(u,v)$，再求出用边缘密度函数也就得到 $Z=g(x,y)$ 的边缘密度函数

① 做变换，求变换因子

设 $\begin{cases}u=g(x,y)\\v=h(x,y)\end{cases}$ 其有唯一的逆变换 $\begin{cases}x=x(u,v)\\y=y(u,v)\end{cases}$

变换因子为其所有各比行列式的值

$$J(u,v)=\begin{vmatrix}\frac{\partial x}{\partial u} & \frac{\partial x}{\partial v}\\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v}\end{vmatrix}$$

$(x,y)=T^{-1}(u,v)$

则 $dxdy=|J|dudv$

② 求 $F_{u,v}(u,v)$ 和 $P_{u,v}(u,v)$

$$F_{u,v}(u,v)=\int_{-\infty}^{u}\int_{-\infty}^{v} P(x(u_0,v_0),y(u_0,v_0))\left|J(u_0,v_0)\right|du_0dv_0$$

得 $P_{u,v}(u,v)=P(x(u,v),y(u,v))\left|J(u,v)\right|$

例：设 X、Y 独立同分布于标准正态分布 $N(0,1)$

联合分布为 $f_{X,Y}(x,y)=\frac{1}{2\pi}e^{-\frac{x^2+y^2}{2}}$

考虑变换 $U=X+Y$，$V=X-Y$，

逆变换：$X=\frac{U+V}{2}$　$Y=\frac{U-V}{2}$

雅各比行列式：$J=\begin{vmatrix}\frac{\partial x}{\partial u} & \frac{\partial x}{\partial v}\\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v}\end{vmatrix}=\begin{vmatrix}\frac{1}{2} & \frac{1}{2}\\ \frac{1}{2} & -\frac{1}{2}\end{vmatrix}=-\frac{1}{2}$

$$f_{U,V}(u,v)=\frac{1}{2\pi}e^{-\frac{1}{2}\left[\left(\frac{u+v}{2}\right)^2+\left(\frac{u-v}{2}\right)^2\right]}\times\left|-\frac{1}{2}\right|=\frac{1}{4\pi}e^{-\frac{u^2+v^2}{4}}$$

$$=\frac{1}{\sqrt{4\pi}}e^{-\frac{u^2}{4}}\times\frac{1}{\sqrt{4\pi}}e^{-\frac{v^2}{4}}\quad\sim N(0,2)$$

求边缘分布

$$P_U(u)=\int_{-\infty}^{+\infty}P_{U,V}(u,v)\,dv$$

得到的 $P_U(u)$ 就是 $P_Z(z)$

下面是一些常见的公式：

1. 和的分布：$Z=X+Y$

$$P_Z(z)=\int_{-\infty}^{+\infty}P(z-y,y)\,dy=\int_{-\infty}^{+\infty}P(x,z-x)\,dx$$

$$=\int_{-\infty}^{+\infty}P_X(z-y)P_Y(y)\,dy=\int_{-\infty}^{+\infty}P_X(x)P_Y(z-x)\,dx$$

2. 差的分布：$Z=X-Y$

$$P_Z(z)=\int_{-\infty}^{+\infty}P(x,x-z)\,dx=\int_{-\infty}^{+\infty}P(y+z,y)\,dy$$

$$=\int_{-\infty}^{+\infty}P_X(x)P_Y(x-z)\,dx=\int_{-\infty}^{+\infty}P_X(y+z)P_Y(y)\,dy$$

3. 积的分布：$Z=XY$

$$P_Z(z)=\int_{-\infty}^{+\infty}P\left(\frac{z}{y},y\right)\frac{1}{|y|}\,dy=\int_{-\infty}^{+\infty}P\left(x,\frac{z}{x}\right)\frac{1}{|x|}\,dx$$

4. 商的分布：$Z=\frac{X}{Y}$

$$P_Z(z)=\int_{-\infty}^{+\infty}P(zy,y)|y|\,dy=\int_{-\infty}^{+\infty}P\left(x,\frac{x}{z}\right)\left|\frac{x}{z^2}\right|dx$$

5. max的分布 $N=\max\{X,Y\}$

$P(\max(X,Y)\le z)=P(X\le z, Y\le z)$

$F_N(z)=F(x,y)=F_X(x)F_Y(y)$

6. min的分布 $N=\min\{X,Y\}$

$F_N(z)=P(\min(X,Y)\le z)=1-P(\min(X,Y)>z)$

$=1-P(X>z, Y>z)=1-(1-P(X\le z))(1-P(Y\le z))$

$\therefore F_N(z)=1-[1-F_X(z)][1-F_Y(z)]$

7. 条件分布

设X的分布函数为$F(x)=P(X\le x)$，则A发生条件下X的分布函数为$F(x|A)=P(X\le x|A)=\frac{P(X\le x,A)}{P(A)}$

① 对于离散型二维随机变量

$$P(X=x_i|Y=y_j)=\frac{P(X=x_i,Y=y_j)}{P(Y=y_j)}=\frac{P_{ij}}{P_{\cdot j}}$$

当X、Y独立时，条件分布成为无条件分布

② 对于连续型二维随机变量

若$\lim\limits_{\varepsilon\to 0}P(X\le x|y\le Y<y+\varepsilon)=\lim\limits_{\varepsilon\to 0}\frac{P(X\le x,y\le Y<y+\varepsilon)}{P(y\le Y<y+\varepsilon)}$

极限存在，则称为Y=y条件下X的条件分布函数

$$F_{X|Y=y}(x)=\int_{-\infty}^{x}\frac{P(u,y)}{P_Y(y)}du$$

$$P_{X|Y=y}(x)=\frac{P(u,y)}{P_Y(y)}$$

当X、Y独立时，条件密度成为无条件密度

第四章

1. 数学期望的定义

① 离散型：$E[f(X)] = \sum_{i}^{+\infty} f(x_i) p_i$

要求级数绝对收敛

② 连续型：$E[f(X)] = \int_{-\infty}^{+\infty} f(x) p(x) dx$

要求 $\int_{-\infty}^{+\infty} |f(x)| p(x) dx < +\infty$

要同时注意 $f(x)$ 和 $p(x)$ 的定义域和值域

③ 二维随机变量：

(1) 离散型：$EZ = E[g(X,Y)] = \sum_{i}^{+\infty} \sum_{j}^{+\infty} g(x_i, y_j) P_{ij}$

(2) 连续型：$EZ = E[g(X,Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x,y) p(x,y) dx dy$

(3) 边缘变量的期望：

<1> $P(x,y) \rightarrow P_X(x) \rightarrow E(X)$

<2> $E(X) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x P(x,y) dx dy$

2. 数学期望的性质

(1) 若 a 为常数，则 $E(a) = a$

(2) 对任意有限常数 a, b，$E(aX + bY) = aEX + bEY$

(3) X, Y 相互独立，则 $E(XY) = E(X)E(Y)$

→ 只有无相关，这个是因为 $Cov(X,Y) = 0$，但 $Cov(X,Y) = 0$ 只能说明 X, Y 没有线性关系，并不一定能独立

$E(XY) = E(X)E(Y) + Cov(X,Y)$

用期望的性质化简求期望的过程：

将n个球放入M个盒子，设每个球落入每个盒子是等可能的，求有球盒子个数X的期望

① 期望性质法

化为独立样本点之和随机变量 $X_i = \begin{cases} 1, & i盒中有球 \\ 0, & i盒中无球 \end{cases}$

故有 $X = X_1 + \cdots + X_M$

求样本点期望 $E(X_i) = P(X_i=1) = 1 - P(X_i=0) = 1 - \left(\frac{M-1}{M}\right)^n$

求出总体 $EX = MEX_i = M\left[1 - \left(\frac{M-1}{M}\right)^n\right]$

客车上有10名乘客，共10个车站，每个人在各车站下车的概率相等且独立，X为停车的次数，求E(X)

$X_i = \begin{cases} 1 & 有人下车 \\ 0 & 无人下车 \end{cases}$ $\quad X = X_1 + \cdots + X_{10}$

$E(X_i) = P(X_i=1) = 1 - P(X_i=0) = 1 - \left(\frac{9}{10}\right)^{20}$

$E(X) = 10E(X_i) = 10\left(1 - \left(\frac{9}{10}\right)^{20}\right)$

帽子问题 = 编号为1~n的球放入编号为1~n的盒子中.
(匹配问题) 如果一只球装入与之编号相同的盒子中, 则称为1个配对. X为总配对数.

1. 求E(X), 总配对数的期望

$X_i = \begin{cases} 0, & \text{配对失败} \\ 1, & \text{配对成功} \end{cases}$ $X = X_1 + \cdots + X_n$

$E(X_i) = P(X_i = 1) = \frac{1}{n}$ $E(X) = nE(X_i) = 1$

2. 求没有成功匹配的概率为多少

方法1: 容斥原理

设 X_i 表示 "编号为i的球和盒子成功匹配"

由容斥原理, 至少存在1个配对的概率为:

$$P(\bigcup_{i=1}^{n} X_i) = \sum_{i=1}^{n} P(E_i) - \sum_{i_1<i_2} P(E_{i_1}E_{i_2}) + \cdots + (-1)^{k+1} \sum_{i_1<\cdots<i_k} P(E_{i_1}\cdots E_{i_k})$$
$$+ \cdots + (-1)^{n+1} P(E_1 \cdots E_n) = \sum_{k=1}^{n} (-1)^{k+1} P(\bigcup_{i=1}^{k} X_i)$$

样本总体为 $n!$, 假定有k个匹配, 则剩下的小球和盒子可能匹配, 也可能不匹配, 这种情况下还有 $(n-k)!$ 种可能的结果

因此 $P(X_{i_1} \cdots X_{i_k}) = \frac{(n-k)!}{n!}$ (基于容斥原理, 不是"只有", 而是"有")

又: 从n个人中选择k个特定的人一共有 C_n^k 种可能

$\therefore \sum_{i_1<\cdots<i_k} P(X_{i_1} \cdots X_{i_k}) = C_n^k \frac{(n-k)!}{n!} = \frac{1}{k!}$

将上式化为容斥公式=

$$P(\bigcup_{i=1}^{n} X_i) = 1 - \frac{1}{2!} + \cdots + (-1)^{n+1}\frac{1}{n!} = \sum_{1}^{n}(-1)^{i+1}\frac{1}{i!}$$

因此，没有任何匹配的概率为

$$1 - P(\bigcup_{i=1}^{n} X_i) = \frac{1}{2!} - \cdots + (-1)^{n}\frac{1}{n!} = \sum_{0}^{n}(-1)^{i}\frac{1}{i!}$$

$$\lim_{n\to\infty} 1 - P(\bigcup_{i=1}^{n} X_i) = \frac{1}{e}$$

故没有任何匹配的概率为 $\sum_{0}^{n}(-1)^{i}\frac{1}{i!}$，当n足够大时趋近于 e^{-1}

方法2：条件概率

设F表示事件"n个小球和盒子都没有完成匹配"，记 $P_n = P(F)$

设M为第1个小球成功匹配，M^c为第1个小球匹配失败

$$P_n = P(F) = P(F|M)P(M) + P(F|M^c)P(M^c)$$

显然有 $P(F|M) = 0$

$$\therefore P_n = P(F) = P(F|M^c)P(M^c) = P(F|M^c)\frac{n-1}{n}$$

$P(F|M^c)$是在第1个N球和盒子匹配失败的概率，剩下的n-1个小球里有一个特殊的N球，这个N球一定不可能匹配成功

这里有两种不相容的可能：

- 这个N球选到了第1个小球对应的盒子，概率为 P_{n-1}
- 这个小球没有选到第1个N球对应的盒子，概率为 $\frac{P_{n-2}}{n-1}$

$$\therefore P(F|M^c) = P_{n-1} + \frac{P_{n-2}}{n-1}$$ 代入上面的全概率公式得

$$P_n = \frac{n-1}{n}P_{n-1} + \frac{1}{n}P_{n-2}$$

$P_n = \frac{n-1}{n} P_{n-1} + \frac{1}{n} P_{n-2}$ 等价于 $P_n - P_{n-1} = -\frac{1}{n}(P_{n-1} - P_{n-2})$

P_n表示n个小球和盒子没有配对的概率，初始条件 $P_1 = 0$ $P_2 = \frac{1}{2}$

则 $P_2 - P_1 = \frac{1}{2!}$ $P_3 - P_2 = \frac{-1}{3!}$ $P_4 - P_3 = \frac{1}{4!}$ … $P_n - P_{n-1} = \frac{(-1)^n}{n!}$

将上面各式相加得到 $P_n = \frac{1}{2!} - \frac{1}{3!} + \dots + (-1)^n \frac{1}{n!} = \sum_{i=0}^{n} \frac{(-1)^i}{i!}$

3. 求刚好有k个成功匹配

先从n个小球里选出特定的k个小球，设事件E表示"这k个小球都成功匹配"，G表示"剩下的n-k个小球都没有匹配成功"，根据乘法法则，则有：

$P(EG) = P(E)\,P(G|E)$ EG表示：只有这k个小球成功匹配

已知 $P(E) = \frac{(n-k)!}{n!}$ $P(G|E) = P_{n-k} = \sum_{i=0}^{n-k} \frac{(-1)^i}{i!}$

$\therefore P(EG) = \frac{(n-k)!}{n!} \sum_{i=0}^{n-k} \frac{(-1)^i}{i!}$

∵从n个人中选择k个人共有 C_n^k 种可能

$\therefore P = C_n^k P(EG) = \frac{1}{k!} \sum_{i=0}^{n-k} \frac{(-1)^i}{i!}$

$\lim_{n \to +\infty} P = \frac{e^{-1}}{k!}$

4. 拿到自己帽子的人数的方差

方法1：$E(C_X^2)$公式法

特定的两个小球成功匹配的概率是 $\frac{1}{N(N-1)}$，记作 $P(E_iE_j)$

$E(C_X^2) = \sum_{i<j} C_N^2 P(E_iE_j) = C_N^2 \frac{1}{N(N-1)} = \frac{1}{2} = E(X(X-1))/2$

$\therefore EX^2 = 1 + EX = 2$ $D(X) = EX^2 - (EX)^2 = 1$

方法2：方差性质法

由于X_i是示性变量，可以当作伯努利随机变量

$E(X_i)=\frac{1}{n}$，$D(X_i)=\frac{1}{n}(1-\frac{1}{n})=\frac{n-1}{n^2}$

对于任意$i\neq j$，有

$$\begin{aligned}Cov(X_i,X_j)&=E(X_iX_j)-E(X_i)E(X_j)\\&=\frac{1}{n(n-1)}-\frac{1}{n^2}=\frac{1}{n^2(n-1)}\end{aligned}$$

$$\begin{aligned}\therefore D(X)=D(\sum X_i)&=\sum D(X_i)+2\sum_{1\leq i<j\leq n}Cov(X_i,X_j)\\&=n\times\frac{n-1}{n^2}+C_n^2\frac{2}{n^2(n-1)}=1\end{aligned}$$

3. 方差的定义和性质

$$D(X)=E(X-EX)^2=EX^2-(EX)^2$$

方差的性质：

1. 任意常数 a，$D(a)=0$

2. a,b 为任意有限常数，若 X 的方差存在，则 $D(aX+b)=a^2D(X)$

3. $D(X\pm Y)=D(X)+D(Y)\pm 2E[(X-EX)(Y-EY)]$，$E[(X-EX)(Y-EY)]=cov(X,Y)$

   还是只能从方往边推

   当 X 和 Y 独立时 $D(X\pm Y)=D(X)\pm D(Y)$

4. $D(X)=0$，则 $P(X=EX)=1$，$X=EX$（切比雪夫不等式）

5. $D(\sum_{i=1}^{n}X_i)=\sum_{i=1}^{n}D(X_i)+2\sum_{1\le i<j\le n}Cov(X_i,X_j)$

4. 相关系数

① 柯西不等式：$(cov(X,Y))^2\le D(X)D(Y)$

当且仅当 X 和 Y 线性相关时等号成立

柯西不等式的性质源于二次式的判别式性质。

构造 $u(t)=E[t(X-EX)-(Y-EY)]^2=D(tX-Y)$

② 相关系数：$\rho_{XY}=\dfrac{cov(X,Y)}{\sqrt{D(X)D(Y)}}=Corr(X,Y)$

1. $\rho_{XY}=0$
2. $cov(X,Y)=0$
3. $E(XY)=EX\cdot EY$
4. $D(X\pm Y)=D(X)+D(Y)$

} X 和 Y 线性无关

5. 切比雪夫不等式：

$$P(|X-EX|\geq\varepsilon)\leq\frac{DX}{\varepsilon^2}$$

偏移期望ε的概率不大于$\frac{DX}{\varepsilon^2}$

用于估计中部事件 ⇒

DX越小，X越向EX集中 ≤

$$P(|X-EX|\geq\varepsilon)=\int_{k:|x-EX|\geq\varepsilon} p(x)\,dx \leq \int_{k:|x-EX|\geq\varepsilon}\frac{(x-EX)^2}{\varepsilon^2}p(x)\,dx=\frac{DX}{\varepsilon^2}$$

切比雪夫不等式只与样本的数字特征有关，与样本的分布无关

当一些随机变量只给出期望和方差时，可以用其估计概率

切比雪夫不等式证明方差为0时随机变量为常数

$$0\leq P(|X-EX|\geq\varepsilon)\leq\frac{DX}{\varepsilon^2}=0$$

$$\therefore P(X\neq EX)=P\left(\bigcup_{i=1}^{n}\left\{|X-EX|\geq\frac{1}{n}\right\}\right)=\lim_{n\to\infty}P\left(|X-EX|\geq\frac{1}{n}\right)=0$$

$$\therefore P(X=EX)=1$$ 随机变量X几乎处处收敛于一常数

马尔可夫不等式：

$$P(|X|\geq\varepsilon)\leq\frac{E(|X|^k)}{\varepsilon^k}$$

$$P(|f(x)|\geq\varepsilon)\leq\frac{E(|f(x)|^k)}{\varepsilon^k}$$

随机变量的函数不小于其正数的概率上界

用于估计尾部事件 ⇒

$\frac{1}{\varepsilon}E(|X|)$越小则$P(|X|\geq\varepsilon)$越小 ≤

用马尔可夫不等式推导切比雪夫不等式：

$$P(|X-EX|\geq\varepsilon)=P(|X-EX|^2\geq\varepsilon^2)\leq\frac{E(|X-EX|^2)}{\varepsilon^2}=\frac{DX}{\varepsilon^2}$$

当$EX=0$时，切比雪夫不等式退化成马尔可夫不等式

马尔可夫不等式估计尾部事件

$\varepsilon=CE(|X|^k)$，则$P(|X|\geq CE(|X|^k))\leq\frac{1}{C}$

（如$k=1$时，意味着超过C倍期望的样本数不会超过总体的$\frac{1}{C}$）

马尔克夫不等式证明：

$$E(|X|^k) = \int_0^{+\infty} |x|^k p(x)\,dx \geq \int_a^{+\infty} |x|^k p(x)\,dx$$

$$\geq \int_a^{+\infty} a^k p(x)\,dx \geq a^k P(|X| \geq a)$$

对于随机变量的低阶数字特征，马尔可夫提供的上界大过宽松，更适合使用切比雪夫不等式

第 5 章

零、测度：

对于概率论的学习，我们只讨论实数集 $\mathbb{R}$ 中的勒贝格测度

从几何角度看：$m\mathbb{C}$ 就是 $\mathbb{C}$ 的定义长度

从概率角度看：确定区间 $[0,1]$ 的某个子集的测度，就是确定在 $[0,1]$ 中随机一点在子集中的概率

性质：1. $mA \geq 0 \quad (\forall A \in \mathbb{R})$

2. $m\emptyset = 0$

3. $m(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} mA_i \quad (\forall A_i \subset \mathbb{R} \text{ 且 } \forall A_i, A_j \ A_i \cap A_j = \emptyset)$

$\bigcup_{i=1}^{+\infty}$ 对应正整数集 $\mathbb{I}^+$，指可数个集合的测度满足可列可加性

首先定义开集的测度

首先定义开集：

$\mathbb{R}$ 上的开集 A 满足 $(\forall x - x_0, x + x_0) \subset A, (\forall x \in A, \exists x_0 \in \mathbb{R})$

也即 $A = \bigcup_{i=1}^{\infty} A_i$，其中 A_i 是开区间

记 $A_i = (a_i, b_i)$ 则 $mA_i = b_i - a_i$，开集的测度可以如此表示

然后定义闭集的测度

对于任意闭集 $\mathbb{B}$，$\mathbb{B} = \mathbb{C} / \mathbb{B}$，$\mathbb{B}$ 是开集，$\mathbb{C}$ 是 $\mathbb{R}$ 上的开总集

则 $m\mathbb{B} = m\mathbb{C} - m\mathbb{B}$

粗略地来讲，对于任意有界集合 $\mathbb{C}$，$\mathbb{C}$ 的外测度是 $\mathbb{C}$ 对应闭集的测度，记作 $m^*\mathbb{C}$，$\mathbb{C}$ 的内测度是 $\mathbb{C}$ 对应开集的测度，记作 $m_*\mathbb{C}$。

当 $m^*\mathbb{C} = m_*\mathbb{C}$ 时，称 $\mathbb{C}$ 是可测的，且测度为 $m\mathbb{C}$

证明可数点集一定是零测集：

$\forall m_0, x_0 \in \mathbb{R}$，取 $(m_0 - x_0, m_0 + x_0) \in \mathbb{R}$，

则 $m^*(\{m_0\}) = m((m_0 - x_0, m_0 + x_0)) - m((m_0 - x_0, m_0)) - m((m_0, m_0 + x_0)) = 0$

$m_*(\{m_0\}) = m((m_0, m_0)) = 0$

故 $m(\{m_0\}) = 0$

由可数点集的定义知 可数点集 $E = \bigcup_{i \in \mathbb{I}} E_i$，故 $m(E) = \sum_{i=1}^{\infty} m(E_i) = 0$

零测集可能是不可数集—康托尔集

为证明之，我们要证明一个零测集和一个不可数集等势
实数数轴上一个长度趋近于0的线段对应的集合是一个零测集
只需构造一个与$\mathbb{R}$等势，并且满足此性质的集合，也就是数轴"不断偏小"的集合

首先，我们都知道，无论在什么进制中，小数集都是不可数的
构造三进制小数集合，并规定其小数数位上的数字不等于1，则其与二进制小数集构成双射，显然是一个不可数集。
其在集合$[0,1]$上，则表示不去掉中间1/3的集合，则

$$m^*\mathbb{C}=\lim_{n\to\infty}\frac{1}{3^n}=0$$

$$m_*\mathbb{C}=\lim_{n\to\infty}1-\sum_{i=1}^{n}\frac{2^{n-1}}{3^n}=0$$

故$m\mathbb{C}=0$　则这个不可数集是一个零测集

一、收敛

数学分析中的强收敛

- 级数(离散型)：条件收敛　弱于　绝对收敛
- 函数(连续型)：逐点收敛　弱于　一致收敛

收敛和极限的相同判别方法 $\varepsilon-\delta$ 语言

逐点收敛：对于$\forall x\in$定义域，$\forall\varepsilon>0$，$\exists N(x,\varepsilon)>0$，当$n>N(x,\varepsilon)$时，$|f_n(x)-f(x)|<\varepsilon$成立，则称$\{f_n(x)\}_{n=1}^{\infty}$逐点收敛于$f(x)$

一致收敛：对于$\forall x\in$定义域，$\forall\varepsilon>0$，$\exists N(\varepsilon)>0$，当$n>N(\varepsilon)$时，$|f_n(x)-f(x)|<\varepsilon$成立，则称$\{f_n(x)\}_{n=1}^{\infty}$一致收敛于$f(x)$

① 一致收敛的N与x的取值无关　② $f_n(x)$可以认为是$f(n,x)$

泛函分析中的收敛

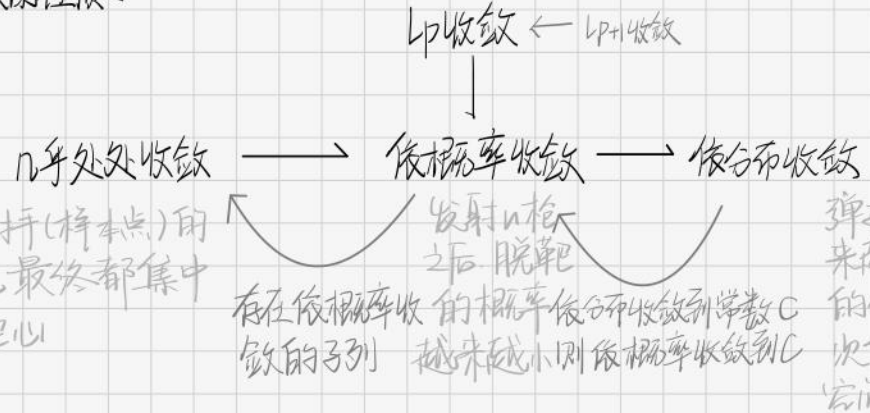
n是样本的个数

- 逐点收敛：$\forall w\in\Omega,\lim_{n\to\infty}X_n(w)=X(w)$，则 $X_n\to X\ (n\to\infty)$　概率无关
- 强收敛　具有一致性：$P\{w\in\Omega:\lim_{n\to\infty}X_n(w)=X(w)\}=1$
  - 要求那些 $X_n(w)\neq X(w)$ 的样本点的测度为0
  - $=\lim_{n\to\infty}P\{\forall w\in\Omega:\forall\varepsilon>0,\exists k\geq n,|X_n(w)-X(w)|\geq\varepsilon\}=0$
  - 强收敛的条件是，样本w要满足对于给定的ε和n，对于所有的$k\geq n$ $|X_k(w)-X(w)|\geq\varepsilon$都不能发生
- 弱收敛：$\lim_{n\to\infty}P\{w\in\Omega:|X_n(w)-X(w)|\geq\varepsilon\}=0$
  - 弱收敛的条件是，样本w要满足对于给定的ε和n，只要在n这一点，$|X_k(w)-X(w)|$不发生就可以了

概率中的收敛

1. 几乎处处收敛 = 逐点
   - $X_n\xrightarrow{a.s.}X$ 或 $P(\lim_{n\to\infty}X_n=X)=1$
2. 依概率收敛　弱
   - $X_n\xrightarrow[n\to\infty]{P}X$ 或 $\lim_{n\to\infty}P(|X-X_n|\geq\varepsilon)=0$
   - 宽测集
3. L^P收敛
   - $\lim_{n\to\infty}E(|X_n-X|^2)=0$
   - 当$P=1$时 $\lim_{n\to\infty}E|X_n-X|=0$，则$X_n$平均收敛于$X$
   - 当$P=2$时，$\lim_{n\to\infty}E((X_n-X)^2)=0$，则$X_n$平方平均收敛于$X$
4. 依分布收敛　弱
   - $X_n\xrightarrow[n\to\infty]{D}X$ 或
   - $\lim_{n\to\infty}F_n(x)=F(x)$ 或 $P(X_n\leq a)\to P(X\leq a)$
   - 依分布收敛只和随机变量的分布相关，所以也可称一系列随机变量依分布收敛于某个分布。

收敛的性质：



① 依分布收敛只通过$F(x)$判别，只与分布有关，和取值无关

② 依概率收敛允许零测点集上取值不同

③ Lp收敛和几乎处处收敛对应马尔可夫/切比雪夫不等式都要求$\exists N$使当$n>N$时平移收敛/相等（没有零测点集不等）

几乎处处收敛(强收敛)的应用：

切比雪夫不等式证明方差为0时随机变量为常数

$$0\le P(|X-EX|\ge\varepsilon)\le\frac{DX}{\varepsilon^2}=0$$

$$\therefore P(X\ne EX)=P\left(\bigcup_{i=1}^{n}\left\{|X-EX|\ge\frac{1}{n}\right\}\right)=\lim_{n\to\infty}P\left(|X-EX|\ge\frac{1}{n}\right)=0$$

$$\therefore P(X=EX)=1$$ 随机变量X几乎处处收敛于一常数

证明依概率收敛：

马尔可夫/切比雪夫：若$E|X_n-X|^p\to0$，则$\forall\varepsilon>0$，

$$P(|X_n-X|>\varepsilon)\le\frac{E|X_n-X|^p}{\varepsilon^p}\to0$$

证明依分布收敛：

若特征函数$\varphi_n(t)\to\varphi(t)$且在$t=0$处连续，则收敛于分布

例1：弱收敛（依分布）但不强收敛（依概率）

$X \sim N(0,1)$，令 X_1 和 X 独立同分布。

则 $X_1 \xrightarrow{d} X$，依分布收敛于 X（分布函数相同）

对 $\forall \varepsilon > 0$，$\because X_1 - X \sim N(0,2)$，$P(|X_1 - X| > \varepsilon) = 2\bar{\Phi}(\frac{\varepsilon}{\sqrt{2}}) > 0$

不随 n 趋于0，故 $X_1 \not\xrightarrow{P} X$

例2：强收敛但不逐点收敛

（经典滑动窗序列）在概率空间 $[0,1]$ 中定义

$X_1 = I_{[0,1]}$，$X_2 = I_{[0,\frac{1}{2}]}$，$X_3 = I_{[\frac{1}{2},1]}$，$X_4 = I_{[0,\frac{1}{3}]}$ ...

则 $\lim_{n\to\infty} \frac{1}{n} = 0$，对 $\forall \varepsilon$，$P(|X_n - 0| > \varepsilon) = \frac{1}{n} \to 0$，故 $X_n \xrightarrow{P} 0$

对于某个 $[0,1]$ 上的固定点 ω，该点会无数多次落在长度为 $\frac{1}{n}$ 的区间中，$X_n(\omega)$ 无限多次取 1 和 0，极限不存在。

二、大数定律

设 $X_1 \dots X_n \dots$ 为随机变量序列，若 $\lim_{n\to\infty} P\left(\left|\frac{1}{n}\sum_{k=1}^{n} X_k - \frac{1}{n}\sum_{k=1}^{n} EX_k\right| \geq \varepsilon\right) = 0$

随机变量序列的取值概率收敛于随机变量序列的均值，则称其满足大数定律

1. 切比雪夫大数定律：

设 $X_1 \dots X_n \dots$ 为两两不相关的随机变量序列，方差一致有界，则其服从大数定律

$$0 \leq P\left(\left|\frac{1}{n}\sum X_k - \frac{1}{n}\sum EX_k\right| \geq \varepsilon\right) = P\left(\left|\frac{1}{n}\sum X_k - E\left(\frac{1}{n}\sum X_k\right)\right| \geq \varepsilon\right)$$

$$\leq D\left(\frac{1}{n}\sum X_k\right)/\varepsilon^2 \quad \overset{\text{两两不相关 } cov(X_i, X_j)=0}{=} \quad \frac{1}{n^2} D\left(\sum_{k=1}^{n} X_k\right)/\varepsilon^2 \xrightarrow{n\to\infty} 0$$

2. 独立同分布大数定律（辛钦大数定律）

设 $X_1 \dots X_n \dots$ 为两两独立且分布相同的随机变量序列，期望存在，则其服从大数定律

3. 伯努利大数定律：

设 n_A 是 n 重伯努利试验中 A 发生的次数，A 发生的概率为 p，

$\lim_{n\to\infty} P\left(\left|\frac{n_A}{n} - p\right| \geq \varepsilon\right) = 0$

4. 马尔可夫大数定律：$\frac{1}{n^2} D\left(\sum X_k\right) \to 0$ 则其服从大数定律

5. 柯尔莫洛夫强大数定律：对应的级数收敛，$\forall n$，$\frac{1}{n^2}\sum^{\infty} D(X_i) \leq \infty$，则其满足强大数定律

三、中心极限定理

对于任意随机变量 X，定义标准化随机变量 $Y = \frac{X - E(X)}{\sqrt{D(X)}}$

若 $\bar{X} = X_1 + X_2 + \dots + X_n$，$X_1 \dots X_n$ 相互独立，则 $\bar{X} \sim N(n\mu, n\sigma^2)$，$\frac{\bar{X}}{\sqrt{n}} \sim N(0,1)$

也即：$\lim_{n\to\infty} P\left(\frac{\sum X_k - n\mu}{\sqrt{n}\sigma} \leq x\right) = \Phi(x)$　$\lim_{n\to\infty} P\left(\frac{n_A - np}{\sqrt{npq}} \leq x\right) = \Phi(x)$

① 独立同分布中心极限定理

② 拉普拉斯中心极限定理

第六章 统计量与抽样分布

1. 总体与样本

随机抽样的性质：1. 代表性：样本分量和总体同分布 2. 独立性

设总体 X 的分布函数为 $F(x)$，则样本 $(X_1 \cdots X_n)$ 的分布函数为

$$F(X_1, X_2, \cdots, X_n) = \prod_{i=1}^{n} F(X_i)$$

若总体是连续型随机变量，其概率密度函数为 $P(x)$，则样本 $(X_1, X_2, \cdots, X_n)$ 的概率密度函数为

$$P(X_1, X_2 \cdots X_n) = \prod_{i=1}^{n} P(X_i)$$

2. 统计量与抽样分布：

设 $(X_1 \cdots X_n)$ 为总体 X 的一个样本，$T(X_1 \cdots X_n)$ 为不含任何未知参数的函数，则称其为一个统计量（一旦有了样本，就可以计算出统计量）

样本均值：$\overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$

样本方差：$S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2$

样本标准差：$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2}$

样本二阶中心矩：$S^{*2} = \frac{1}{n} \sum_{i=1}^{n} (X_i - \overline{X})^2$

样本 k 阶原点矩：$A_k = \frac{1}{n} \sum_{i=1}^{n} X_i^k$

样本 k 阶中心矩：$B_k = \frac{1}{n} \sum_{i=1}^{n} (X_i - \overline{X})^k$

样本相关系数：$S_{XY}=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y})$

$$r=\frac{S_{XY}}{(S^*_X\cdot S^*_Y)}=\frac{\sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i-\bar{X})^2\sum_{i=1}^{n}(Y_i-\bar{Y})^2}}$$

3. 正态分布相关性质

(1) $\bar{X}\sim N(\mu,\frac{\sigma^2}{n})$ $n\to\infty$, $D(\bar{X})\to 0$, $P(\bar{X}\neq\mu)=0$, 几乎处处收敛

(2) $(n-1)\frac{S^2}{\sigma^2}=\frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{\sigma^2}=\sum_{i=1}^{n}(\frac{X_i-\bar{X}}{\sigma})^2\sim\chi^2(n-1)$

(3) $T=\frac{(\bar{X}-\mu)}{S/\sqrt{n}}\sim t(n-1)$ $T_2=\sqrt{\frac{n_1n_2(n_1+n_2-2)}{n_1+n_2}}\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{(n_1-1)S_1^2+(n_2-1)S_2^2}}\sim t(n_1+n_2-2)$

(4) $F=\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}\sim F(n_1-1,n_2-1)$

(5) $\bar{X}$与S^2相互独立

如果一个球员，投篮水平是完全正态的，则其投篮位置的中心和分散程度是独立的。

取$X=\begin{bmatrix}X_1\\X_2\\\vdots\\X_n\end{bmatrix}$，构造$Y_1=\sqrt{n}\bar{X}=\frac{X_1}{\sqrt{n}}+\cdots+\frac{X_n}{\sqrt{n}}$，则$Y_1=[\frac{1}{\sqrt{n}},\frac{1}{\sqrt{n}}\cdots\frac{1}{\sqrt{n}}]\begin{bmatrix}X_1\\X_2\\\vdots\\X_n\end{bmatrix}=A_1X$

构造$A=\begin{bmatrix}A_1\\A_2\\\vdots\\A_n\end{bmatrix}$，则$Y=\begin{bmatrix}Y_1\\Y_2\\\vdots\\Y_n\end{bmatrix}=AX$

$Y_1^2+Y_2^2+\cdots+Y_n^2=Y^TY=X^TA_1^TA_1X=X^TX=X_1^2+X_2^2+\cdots+X_n^2=n^2\bar{X}^2$

故$Y_2^2+\cdots+Y_n^2=(X_1^2+\cdots+X_n^2)-n\bar{X}^2=\sum(X_i-\bar{X})^2=(n-1)S^2$ 故$(n-1)\frac{S^2}{\sigma^2}\sim\chi^2(n-1)$

$Var(Y)=Var(AX)=AVar(X)A^T=A\sigma^2I_nA^T=\sigma^2I_n$

$X_n\sim N(\sqrt{n}a_1\cdot\mu,\sigma^2I_n)$，$Y_n\sim N(\sqrt{n}A\cdot a_1\cdot\mu,\sigma^2I_n)$

故$Y_1,Y_2\cdots Y_n$独立，又$Y_1=\sqrt{n}\bar{X}$，故$\bar{X}$与$Y_2^2+Y_3^2+\cdots+Y_n^2$独立，

故$\bar{X}$与S^2独立

3. 正态总体

一、χ^2分布 $\chi^2(n)$，期望 n，方差 $2n$

$X_1 \cdots X_n \sim N(0,1)$，则 $\chi_n^2 = \sum_{i=1}^{n} X_i^2$ 为服从自由度为 n 的 χ^2 分布，记为 $\chi_n^2 \sim \chi^2(n)$

χ^2 分布的密度函数

$$P(x) = \begin{cases} \frac{1}{2^{n/2}\Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1} & x>0 \\ 0 & x \le 0 \end{cases}$$

$\Gamma(x) = \int_0^{\infty} u^{x-1} e^{-u} du$

$\Gamma(x) = \int_0^{\infty} u^{\frac{n}{2}-1} e^{-u} du$

χ^2 分布的性质：

1. 再生性：$\chi_1^2 \sim \chi^2(n_1)$，$\chi_2^2 \sim \chi(n_2)$，且 χ_1^2 与 χ_2^2 相互独立，则有 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1+n_2)$

2. 数字特征：若 $\chi^2 \sim \chi^2(n)$，则 $E(\chi^2) = n$，$D(\chi^2) = 2n$

3. 图像特征：随着自由度的增加，重心不断移动，曲线趋于平缓

柯赫伦分解定理：

$X_i \sim N(0,1)$，使 $\sum_{i=1}^{n} X_i^2 = \chi_n^2 = \sum_{i=1}^{k} Q_i$，其中 Q_i 是秩为 n_i 的 $X_1 \cdots X_n$ 的非负二次型，则 Q_i 相互独立且分别服从自由度为 n_i 的 χ^2 分布的充要条件为 $n_1 + n_2 + \cdots + n_k = n$

χ 分布是由正态分布的样本方差构造来的，卡方检验用于检验总体方差 σ^2 的置信区间

二、t分布

$$T=\frac{X}{\sqrt{Y/n}}=\frac{\sqrt{n}X}{\sqrt{Y}}$$

$X\sim N(0,1)$
$Y\sim \chi^2(n)$
$T\sim t(n)$

t分布的密度函数 $P(x)=\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\,\Gamma(\frac{n}{2})}(1+\frac{x^2}{n})^{-\frac{n+1}{2}}$

$t(n)$ 期望0，方差 $\frac{n}{n-2}$ $(n>2)$

t分布是用样本标准差替代总体标准差之后的"标准化"统计量.

t分布的性质

1. 密度函数是偶函数，关于y轴对称

2. 当$n\to\infty$时，$\frac{1}{n}\to E(X_i^2)=1$，$T=X\sim N(0,1)$，$P(x)$收敛于$\varphi(x)$

3. n较小时，t分布与标准正态分布的差别较大，t分布有个更大的尾部（n越大，中间越减高，两边越减低）

设$X_1,X_2,\cdots X_n$是来自正态总体$N(\mu,\sigma^2)$的一个样本，则

$$T=\frac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t(n-1)$$

$\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma}\sim N(0,1)$，$\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$ 相互独立

$$\therefore T=\frac{\sqrt{n}(\bar{X}-\mu)}{S}=\frac{|\bar{X}-\mu|/(\sigma/\sqrt{n})}{\sqrt{(n-1)S^2/\sigma^2}}\cdot\sqrt{n-1}=\frac{\sqrt{n-1}\,N(0,1)}{\sqrt{\chi^2(n-1)}}\sim t(n-1)$$

$$T=\sqrt{\frac{n_1n_2(n_1+n_2-2)}{n_1+n_2}}\cdot\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{(n_1-1)S_1^2+(n_2-1)S_2^2}}\sim t(n_1+n_2-2)$$

$\bar{X}-\bar{Y}\sim N(\mu_1+\mu_2,(\frac{1}{n_1}+\frac{1}{n_2})\sigma^2)$　$[(n_1-1)S_1^2+(n_2-1)S_2^2]/\sigma^2\sim\chi^2(n_1+n_2-2)$

$$T=\frac{\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sigma\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}}{\sqrt{(n_1-1)S_1^2/\sigma^2+(n_2-1)S_2^2/\sigma^2}/\sqrt{n_1+n_2-2}}\sim t(n_1+n_2-2)$$

三、F分布

$F(n_1,n_2)$ 期望 $= \frac{n_2}{n_2-2}$

$F = \frac{U/n_1}{V/n_2}$ $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$, $F \sim F(n_1,n_2)$

方差 $= 2n^2(m+n-2) / m(n-2)^2(n-4)$

F分布的密度函数

$$p(x) = \begin{cases} \frac{\Gamma[(n_1+n_2)/2]}{\Gamma(n_1/2)\Gamma(n_2/2)} \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} x^{\frac{n_1}{2}-1} \left(1+\frac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}}, & x>0 \\ 0, & x \le 0 \end{cases}$$

两个独立样本方差平均的比值

用于检验两个正态总体的方差是否相等

F分布性质：

1. 若 $F \sim F(n_1,n_2)$，则 $\frac{1}{F} \sim F(n_2,n_1)$

2. 若 $T \sim t(n)$，则 $T^2 \sim F(1,n)$

若 $X_1 \cdots X_{n_1}$ 来自正态总体 $N(\mu_1,\sigma_1^2)$，$Y_1 \cdots Y_{n_2}$ 来自正态总体 $N(\mu_2,\sigma_2^2)$，两样本相互独立

则 $F = \frac{S_1^2\sigma_2^2}{S_2^2\sigma_1^2} \sim F(n_1-1,n_2-1)$

$$F = \frac{S_1^2\sigma_2^2}{S_2^2\sigma_1^2} = \frac{\frac{1}{n_1-1}\chi^2(n_1-1)}{\frac{1}{n_2-1}\chi^2(n_2-1)} = F(n_1-1,n_2-1)$$

第七章 参数估计

参数估计 = 用样本的分布近似总体的分布
用样本观察值的分布近似样本的分布

一、矩估计

总体分布 $F(x;\theta)$，下列画了一种分布（B，P等），θ是参数，x是统计量
$\theta=(\theta_1,\theta_2\dots\theta_k)'$为k维向量，如 $P(1)$，则θ是1所有可能取值的向量
从总体中抽取样本 $x_1,x_2\dots x_n$，则构造统计量 $\hat{\theta}(x_1,x_2\dots x_n)$ 为θ的估计量
样本对应一组观察值 $x_1,x_2\dots x_n$，则 $\hat{\theta}(x_1,x_2\dots x_n)$ 为θ的估计值

(1) 求总体的各阶原点矩

$$\mu_i=g_i(\theta_1,\theta_2,\dots,\theta_k),\ i=1,2,\dots,k$$

μ_i可以由$\theta_1\dots\theta_k$表示，得到 μ_i和θ_i的方程组

(2) 则参数θ_i可以表示为总体矩的函数，解方程组得

$$\theta_i=h_i(\mu_1,\mu_2,\dots,\mu_k),\ i=1,2,\dots,k$$

(3) 用样本矩代替总体矩，样本矩有观察值所以可求

$$\hat{\theta}_i=h_i(A_1,A_2,\dots,A_k),\ i=1,2,\dots,k$$

因为根据分布函数和密度函数反解方程组很困难，因此矩估计使用样本的数字特征（k阶中心矩）和参数的关系来估计参数，正因为与分布的具体形式无关，只与分布的数字特征有关，所以矩估计的精度不高

矩估计相合性：由大数定律，$A_j=\frac{1}{n}\sum x_i^j \xrightarrow{P} \mu_j$

若h为已知的连续函数，则 $h(A_1,A_2\dots A_k)\xrightarrow{P} h(\mu_1,\mu_2\dots\mu_k)$

二、极大似然估计

参数在此估计值时样本发生的可能性最大

总体为X的随机变量密度函数为 $p(x;\theta)$，样本$(x_1,x_2,\dots,x_n)$落在观察值邻域的概率近似为 $\pi p(x_i;\theta)dx_i$，选取使得上面的概率达到最大的参数值$\hat{\theta}$作为θ的估计

记 $L(x_1,x_2\dots x_n;\theta)=\prod_{i=1}^{n}p(x_i;\theta)$

则有性质 $L(x_1,x_2\dots x_n;\hat{\theta})=\max L(x_1,x_2\dots x_n;\theta)$

$\hat{\theta}(x_1,x_2,\dots,x_n)$为$\theta$的极大似然估计值，$\hat{\theta}(X_1,X_2\dots X_n)$为极大似然估计量

对于对数似然函数 $\ln L(\theta)$，有似然方程组 $\frac{d\ln L(\theta)}{d\theta}=\sum\frac{d\ln p(x_i;\theta)}{d\theta}=0$

这样的解法要求 $L(\theta_i)$作为θ_i的函数是连续的，如果不是连续的，则选择θ_i使$L(\theta_i)$最大

不变性原则：$\hat{\theta}$是参数θ的极大似然估计，$\psi(\theta)$有单值反函数（可测，双射），则$\psi(\hat{\theta})$是$\psi(\theta)$的极大似然估计

上确界的等变性原理，

极大似然估计的应用：定数截尾寿命试验（如何用中位数求平均数（期望））

随机抽取的n个产品（总体）在$t=0$时同时投入试验，试验进行到m个产品失效时停止，m个产品失效的时间分布为 $0 \le t_1 \le t_2 \le \cdots \le t_m$，此时所得的样本 $t_1 \sim t_m$ 称为定数截尾样本

设寿命 $t \sim P(\theta)$，用最大似然估计法来估计 θ

$$p(t_i) = \frac{1}{\theta} e^{-t_i/\theta}, \quad i \in 1 \cdots m$$

其余 $n-m$ 个产品寿命超过 t_m 的概率为

$$\left(\int_{t_m}^{\infty} \frac{1}{\theta} e^{-\frac{t}{\theta}} dt\right)^{n-m} = \left(e^{-\frac{t_m}{\theta}}\right)^{n-m}$$

观察结果出现的概率近似为：

$$\prod_{i=1}^{m} \frac{1}{\theta} e^{-\frac{t_i}{\theta}} dt_i \cdot \left(e^{-t_m/\theta}\right)^{n-m} = \frac{1}{\theta^m} e^{-\frac{1}{\theta}(t_1+\cdots+t_m+(n-m)t_m)} dt_1 dt_2 \cdots dt_m$$

取最大似然函数为 $L(\theta) = \frac{1}{\theta^m} e^{-\frac{1}{\theta}(t_1+t_2+\cdots+t_m+(n-m)t_m)}$

令 $\frac{d \ln L(\hat{\theta})}{d\theta} = 0$，得 $\hat{\theta} = \frac{t_1+\cdots+t_m+(n-m)t_m}{m}$ → 试验的总时间，表示直到 t_m 为止 n个产品的实验时间的总和

最大后验似然估计：

频率学派认为，一个事件发生的概率 θ 是一个固定值，主张以极大似然估计的方法求 θ

贝叶斯学派认为，θ 也是一个随机变量，自身服从一个先验分布，然后基于观测结果 X 来计算后验分布，最后通过后验概率的最大化来确定参数自身的分布，主要方法是最大后验概率估计

假设 θ 也具有某种分布（先验分布）$P(\theta)$，则似然函数为 $P(X|\theta)$

则最大后验似然估计函数为 $P(\theta|X) = \frac{P(X|\theta)P(\theta)}{P(X)}$

$$\hat{\theta} = \operatorname{argmax}_\theta P(\theta|X) = \operatorname{argmax}_\theta \frac{P(X|\theta) \times P(\theta)}{P(X)} = \operatorname{argmax}_\theta P(X|\theta)P(\theta)$$

$$= \operatorname{argmax}_\theta \prod_{i=1}^{n} P(x_i|\theta)P(\theta) = \operatorname{argmax}_\theta \sum \log(P(x_i|\theta)) + \log(P(\theta))$$

$P(\theta)$ 可以是人为考虑一个概率分布，引入 $P(\theta)$ 的目的是为了减少因数据不足导致的偶然性

矩估计例：设 $X_1 \dots X_n$ 独立同分布 $N(\mu, \sigma^2)$，未知参数为 μ 和 σ^2

总体矩：

一阶原点矩 $= E[X] = \mu$

二阶原点矩 $= E[X^2] = \mu^2 + \sigma^2$

样本矩：

一阶样本原点矩 $\frac{1}{n}\sum X_i$

二阶样本原点矩 $\frac{1}{n}\sum X_i^2$

$$\Rightarrow \begin{cases} \hat{\mu} = \frac{1}{n}\sum X_i \\ \hat{\sigma}^2 = \frac{1}{n}\sum (X_i - \bar{X})^2 \end{cases}$$

矩估计自然得到有偏样本方差（且有明显的信息损失）

极大似然估计例：设 $X_1 \dots X_n$ 独立同分布 $N(\mu, \sigma^2)$，未知参数为 μ 和 σ^2

联合密度 $= L(\mu, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_i-\mu)^2}{2\sigma^2}}$

对数似然 $= l(\mu, \sigma^2) = -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(X_i-\mu)^2$

对 μ 求导得 $\frac{\partial L}{\partial \mu} = -\frac{1}{\sigma^2}\sum_{i=1}^{n} X_i - \mu = 0$ 故 $\mu = \frac{\sum_{i=1}^{n} X_i}{n}$

对 σ^2 求导得 $\frac{\partial L}{\partial \sigma^2} = \frac{-n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^{n}(X_i-\mu)^2 = 0$ 故 $\sigma^2 = \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{n}$

因为只使用一二阶矩，故与矩估计的结果相同（且也是有偏估计）

最大后验估计例：设 $X_1 \dots X_n$ 独立同分布 $N(\mu, \sigma^2)$，σ^2 已知，

对 μ 取先验 $\mu \sim N(\mu_0, \tau^2)$

后验 $= P(\mu|X) \propto e^{-\frac{\sum(X_i-\mu)^2}{2\sigma^2}} \cdot e^{-\frac{\sum(\mu-\mu_0)^2}{2\tau^2}}$

取对数（省略常数项）$= \ln P(\mu|X) = -\frac{n}{2\sigma^2}(\mu-\bar{X})^2 - \frac{1}{2\tau^2}(\mu-\mu_0)^2$

对 μ 求导 $= \frac{\partial \ln P(\mu|X)}{\partial \mu} = -\frac{n}{\sigma^2}(\mu-\bar{X}) - \frac{1}{\tau^2}(\mu-\mu_0) = 0$

得 $\mu = \frac{\frac{1}{\sigma^2}n\bar{X} + \frac{1}{\tau^2}\mu_0}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$

三、估计量的评价标准

1、无偏性

设 $\hat{\theta}(X_1, \dots X_n)$ 为参数 θ 的一个估计量，Θ 为参数 θ 的取值范围，若对任意 $\theta \in \Theta$ 有 $E[\hat{\theta}(X_1, X_2, \dots, X_n)] = \theta$，$(P(\hat{\theta} = \theta) = 1)$ 则称 $\hat{\theta}$ 是 θ 的无偏估计量

① 样本的 k 阶原点矩 A_k 是总体 X 的 k 阶原点矩 μ_k 的无偏估计

$$E(A_k) = E(\frac{1}{n}\sum X_i^k) = \frac{1}{n}\sum EX_i^k = \mu_k$$

② 特别地，$\bar{X}$ 是总体的数学期望 EX 的无偏估计

③ 总体 X 的方差 σ^2 存在且有极限，$X_1 \dots X_n$ 是来自总体的一个样本，则样本方差 S^2 是方差 σ^2 的无偏估计

$$S^2 = \frac{1}{n-1}\sum(X_i - \bar{X})^2 = \frac{1}{n-1}\sum X_i^2 - \frac{n}{n-1}(\bar{X})^2$$

$$E(S^2) = \frac{1}{n-1}\sum E(X_i^2) - \frac{n}{n-1}E(\bar{X}^2)$$

$$= \frac{1}{n-1}\sum(\sigma^2 + \mu^2) - \frac{n}{n-1}(\frac{\sigma^2}{n} + \mu^2) = \sigma^2$$

估计意义上的方差是"数据的方差"，而无偏估计的方差是"分布的方差"

$E(\bar{X}^2) = E(\bar{X}^2 - \mu^2) + \mu^2 = E(\bar{X} - \mu)^2) + \mu^2 = D(\bar{X}) + \mu^2 = \frac{\sigma^2}{n} + \mu^2$

因为 $D(\bar{X}) = \frac{\sigma^2}{n}$（均方误差）的存在，低估了 σ^2/n，所以必须要乘 $\frac{n}{n-1}$

同时可以二阶中心矩不是 σ^2 的无偏估计

但有 $E(S^{*2}) = \frac{n-1}{n}\sigma^2 \to \sigma^2$，此时称 S^{*2} 是 σ^2 的渐进无偏估计

④ 当 $\hat{\theta}$ 是 θ 的无偏估计，未必有 $g(\hat{\theta})$ 是 $g(\theta)$ 的无偏估计

例：证明无偏估计：设 $X_1 \dots X_n$ 是来自总体 $X \sim U[0, \theta]$ 的样本，令 $X_{(n)} = \max(X_1, X_2 \dots X_n)$，试证：$\hat{\theta} = \frac{n+1}{n}X_n$ 是 θ 的无偏估计

总体 X 的分布函数为

$$F(x) = \begin{cases} 0, & x \le 0 \\ \frac{x}{\theta}, & 0 < x \le \theta \\ 1, & x > \theta \end{cases}$$

$X_{(n)}$ 的分布函数为 $F^n(x)$，$X_{(n)}$ 的密度函数为

$$P_n(x;\theta) = \begin{cases} \frac{nx^{n-1}}{\theta^n}, & 0 \le x \le \theta \\ 0, & \text{其他} \end{cases}$$

$X_{(n)} = X_i$，则 $F_j(x) \le F_i(x)$，$j \in 1 \dots n$

故 $E(\hat{\theta}) = \frac{n+1}{n}E(X_{(n)}) = \frac{n+1}{n}\int_0^\theta \frac{nx^n}{\theta^n}dx = \frac{n+1}{\theta^n}\frac{x^{n+1}}{n+1}\Big|_0^\theta = \theta$

2. 均方误差准则

均方误差 $M(\hat{\theta},\theta)=E((\hat{\theta}-\theta)^2)=E((\hat{\theta}-E\hat{\theta}+E\hat{\theta}-\theta)^2)$

$=E((\hat{\theta}-E\hat{\theta})^2)+2E((\hat{\theta}-E\hat{\theta})(E\hat{\theta}-\theta))+(E\hat{\theta}-\theta)^2$

$=E((\hat{\theta}-E\hat{\theta})^2)+E(E\hat{\theta}-\theta)^2=D(\hat{\theta})+(E\hat{\theta}-\theta)^2$

均方误差可以分解为 $D(\hat{\theta})$ 和 $(E\hat{\theta}-\theta)^2$ 两部分，如果估计量是无偏估计 $E\hat{\theta}=\theta$，则 $M(\hat{\theta},\theta)=D(\hat{\theta})$

3. 一致性（相合性）

设 $\theta_n(X_1\dots X_n)$ 为参数 θ 的一个估计量，Θ 为参数 θ 的取值范围，若对于任意的 $\theta\in\Theta$，$\hat{\theta}_n\xrightarrow{P}\theta$，则 θ_n 是 θ 的一致估计量（$n\to\infty$，估计量越来越趋近于真实参数）

四. 区间估计

θ 是总体 X 的未知参数，$X_1\dots X_n$ 是来自总体 X 的样本。若对事先给定的常数 $\alpha(0<\alpha<1)$，存在两个统计量 $\hat{\theta}_1(X_1\dots X_n)$ 与 $\hat{\theta}_2(X_1\dots X_n)$ 使 $P(\hat{\theta}_1<\theta<\hat{\theta}_2)=1-\alpha$，则称区间 $(\hat{\theta}_1,\hat{\theta}_2)$ 是 θ 置信度为 $1-\alpha$ 的置信区间，$\hat{\theta}_1$，$\hat{\theta}_2$ 分别称为置信下限和置信上限，$1-\alpha$ 称为置信度或置信系数

在重复取多种样本的情况下，会得到多对 $(\hat{\theta}_1,\hat{\theta}_2)$ 的值，这些区间有 $(1-\alpha)$ 的区间包含 θ

正态分布的置信区间：根据样本的数字特征，将样本转化为某些易得的分布

μ 的置信区间：

σ^2 已知：$\left(\bar{X}-u_{\alpha/2}\frac{\sigma}{\sqrt{n}},\ \bar{X}+u_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right)$，$\left(-\infty,\ \bar{X}+u_\alpha\frac{\sigma}{\sqrt{n}}\right)$，$\left(\bar{X}-u_\alpha\frac{\sigma}{\sqrt{n}},\ +\infty\right)$

σ^2 未知：转化为 t 分布：$T=\frac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t(n-1)$

$$\left(\bar{X}-t_{\alpha/2}(n-1)\frac{S}{\sqrt{n}},\ \bar{X}+t_{\alpha/2}(n-1)\frac{S}{\sqrt{n}}\right)$$

σ^2 的置信区间：

μ 已知：$\left(\left|\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma_{\alpha/2}}\right|,\ +\infty\right)$

μ 未知：转化为 χ^2 分布：$(n-1)S^2/\sigma^2\sim\chi^2(n-1)$

$$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)},\ \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}\right)$$

均值差 $\mu_1-\mu_2$ 的置信区间：

σ_1^2、σ_2^2 均已知：$\left(\bar{X}-\bar{Y}-u_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}},\ \bar{X}-\bar{Y}+u_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n}+\frac{\sigma_2^2}{n}}\right)$

$\sigma_1^2=\sigma_2^2=\sigma^2$，但 σ^2 未知：转化为 t 分布：

$$T=\sqrt{\frac{(n_1+n_2-2)}{\frac{1}{n_1}+\frac{1}{n_2}}}\ \frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{(n_1-1)S_1^2+(n_2-1)S_2^2}} \sim t(n_1+n_2-2)$$

$$\left(\bar{X}-\bar{Y}-t_{\alpha/2}(n_1+n_2-2)S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}},\ \bar{X}-\bar{Y}+t_{\alpha/2}(n_1+n_2-2)S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}\right)$$

其中 $S_W=\sqrt{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}$

方差比 σ_1^2/σ_2^2 的置信区间

μ_1、μ_2 均已知：$\left[\left(\frac{\sqrt{n}(\bar{X}+\bar{Y}-\mu_1-\mu_2)}{u_{\alpha/2}\sigma_2}-1\right)^2,+\infty\right)$

μ_1、μ_2 未知：转为 F 分布，$F=\frac{S_1^2\sigma_2^2}{S_2^2\sigma_1^2}\sim F(n_1-1,n_2-1)$

$$\left(\frac{S_1^2}{S_2^2}\cdot\frac{1}{F_{\alpha/2}(n_1-1,n_2-1)},\ \frac{S_1^2}{S_2^2}\cdot\frac{1}{F_{1-\alpha/2}(n_1-1,n_2-1)}\right)$$

对于较大的样本，可以默认 $\frac{\sum X_i-np}{\sqrt{np(1-p)}}=\frac{\sum X_i-n\mu}{\sqrt{n}\sigma}\sim N(0,1)$

样本和 $\sim N(n\mu,n\sigma^2)$

第八章 假设检验

一、假设检验

H_0 = 原假设/零假设　　H_1 = $\overline{H_0}$ = 备择假设/对立假设

原假设和复合假设各居一边 ⟶ 单边假设
对立假设分居原假设的两边 ⟶ 双边假设

假设中只含有一个假设(A=B)则称为简单假设，否则称为复合假设

过程：

1. 提出 H_0 和 H_1　　检验统计量一定是可计算的
2. (由参数估计)得到合适的统计量，并在 H_0 成立的条件下求统计量的分布　　存伪错误也是在H_0假设的条件下取得的
3. 根据小概率 α，确定临界值和拒绝域W　　第一类错误 = 证明H_0错，弃真
4. 由样本算出统计量的观察值，比较拒绝域和接受域　　H_0、H_1有不同的接受域　　强才　　第二类错误 = 证明H_1对，存伪

P值检验法：

$$P(X_1, X_2, \cdots, X_n) = \sup_{\theta \in \Theta} P_\theta(|T| \geq |t|)$$

检验统计量　　观察值

P值是基于样本观察值而计算出的拒绝原假设的概率
(当原假设为复合假设时，取最大概率)

错误类型1：$P(\text{拒绝}H_0 | H_0\text{为真}) \geq 1-\alpha$

错误类型2：$P(\text{接受}H_1 | H_1\text{为假}) \geq 1-\alpha$

两种错误的概率此消彼长，只有扩大样本容间才能将两种错误的概率都降低

二、正态总体的假设检验

单个总体 $N(\mu, \sigma^2)$

μ 的假设检验

σ^2 已知（u检验）：$U=\dfrac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \sim N(0,1)$

双边 $W=\{|U| \geq u_{\alpha/2}\}$

单边 $W=\{U \geq u_{\alpha}\}$

σ^2 未知（t检验）：$T=\dfrac{\bar{X}-\mu_0}{S/\sqrt{n}} \sim t(n-1)$

$W=\{|U| \geq t_{\alpha/2}^{(n-1)}\}$

σ^2 的假设检验：

μ 已知（u检验）：$U=\dfrac{\bar{X}-\mu}{\sigma_0/\sqrt{n}} \sim N(0,1)$

$W=\{|U| \geq u_{\alpha/2}\}$

μ 未知（χ^2检验）：$\chi^2=\dfrac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$

$W=\{\chi^2 \leq \chi^2_{1-\alpha/2}(n-1)\} \cup \{\chi^2 \geq \chi^2_{\alpha/2}(n-1)\}$

以正态假设检验为例，

统计量：$\dfrac{\bar{X}-\mu_0}{\sigma/\sqrt{n}}$，$H_0: \mu \leq \mu_0$，$H_1: \mu > \mu_0$

$P(\text{拒绝}H_0 \mid H_0\text{为真}) = P(\bar{X}\text{在拒绝域中} \mid \mu \leq \mu_0)$

$= P\left(\dfrac{\bar{X}-\mu}{\sigma/\sqrt{n}} \geq u_\alpha \mid \mu \leq \mu_0\right) \leq P\left(\dfrac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \geq u_\alpha\right)$

若 $P\left(\dfrac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \geq u_\alpha\right) \leq \alpha$，则 $P(\text{拒绝}H_0 \mid H_0\text{为真}) \leq \alpha$

若 $\dfrac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \geq u_\alpha$，则拒绝 $H_0 \mid H_0$ 为真

两个总体 $N(\mu_1, \sigma_1^2)$, $N_2(\mu_2, \sigma_2^2)$ =

两个总体要将其(相减)化成一个总体, $N_1 - N_2 \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$

$\bar{X} \sim N_1(\mu_1, \frac{\sigma_1^2}{n_1})$ $\bar{Y} \sim N_2(\mu_2, \frac{\sigma_2^2}{n_2})$ $\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$

μ的差的假设检验($\mu_1 = \mu_2$?)

σ_1^2, σ_2^2均已知: $U = \dfrac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$, $W = \{|U| \geq u_{\alpha/2}\}$

$\sigma_1^2 = \sigma_2^2 = \sigma^2$, 但未知: $T = \dfrac{\sqrt{n_1 + n_2 - 2}}{\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \dfrac{\bar{X} - \bar{Y}}{\sqrt{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}}$, $W = \{|T| \geq t_{\alpha/2}(n_1 + n_2 - 2)\}$

$\sim t(n_1 + n_2 - 2)$

σ^2的比的假设检验

μ_1, μ_2均未知: $F = \dfrac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$ $W = \{F \leq F_{1-\alpha/2}(n_1 - 1, n_2 - 1)$

$\cup \{F \geq F_{\alpha/2}(n_1 - 1, n_2 - 1)\}$

三、拟合优度检验：检验分布是否为正态分布

皮尔逊 χ^2 拟合优度检验：$H_0: P(X=x_i)=p_i$

(1) 计算 $(x_1, x_2, \dots, x_n)$ 中取 x_i 的实际频数 n_i

(2) 皮尔逊 χ^2 统计量：$\chi^2=\sum_{i=1}^{k}\frac{(n_i-np_i)^2}{np_i}$ 实际频数与理论频数的偏差平方和

χ^2 越大则拟合程度越差，假设 H_0 为真时 $\chi^2 \to \chi^2(k-1)$ or $\chi^2(k+r-1)$

(3) 给定显著性水平 α 的情况下，拒绝域为 $W=\{\chi^2 \geq \chi^2_\alpha(k-1)\}$

(2.1) 若分布参数 θ 未知，先算出 θ 的极大似然估计 $\hat{\theta}$

样本总数　理论频数个数　实际频数总数

要求：(1) 大样本 $n \geq 50$　(2) $np_i \geq 5$　(3) $k \in [4, 20]$

可以列表：

x_i	n_i 实际频数	$\hat{p}_i$	$n\hat{p}_i$ 理论频数	$n_i - n\hat{p}_i$	$\frac{(n_i-n\hat{p}_i)^2}{n\hat{p}_i}$

x_i 可以是值 or 区间　$\hat{p}_i$ 理论概率

例：检验一枚骰子是否均匀　投掷 $n=120$ 次，在显著性水平 $\alpha=0.05$ 下能否认为骰子是均匀的？

面数	1	2	3	4	5	6
频数	15	20	22	18	25	20

若假设为真，所有面的期望频数均为 20

面数 i	O_i	E_i	O_i-E_i	$\frac{(O_i-E_i)^2}{E_i}$
1	15		-5	1.25
2	20		0	0
3	22	20	2	0.2
4	18		-2	0.2
5	25		5	1.25
6	20		0	0

$\chi^2=\sum\frac{(O_i-E_i)^2}{E_i}$

$=2.90$

$\chi^2_{0.05,5}=11.070$

$\chi^2 < \chi^2_{0.05,5}$

接受原假设

四. 独立性检验

设$(X_1,Y_1),(X_2,Y_2)\cdots(X_n,Y_n)$为二维总体$(X,Y)$的一个样本，检验$H_0$：X与Y独立

H_0：X与Y独立 $\Leftrightarrow$ $H_0: P_{ij}=P_{i\cdot}\cdot P_{\cdot j}$

$X_{ij}\Rightarrow r\times s$列联表

	B_1	B_2	$\cdots$	B_j	$\cdots$	B_s	行和
A_1	n_{11}	n_{12}	$\cdots$	n_{1j}	$\cdots$	n_{1s}	$n_{1\cdot}$
$\vdots$							
A_i	n_{i1}	n_{i2}	$\cdots$	n_{ij}	$\cdots$	n_{is}	$n_{i\cdot}$
$\vdots$							
A_r	n_{r1}	n_{r2}	$\cdots$	n_{rj}	$\cdots$	n_{rs}	$n_{r\cdot}$
列和	$n_{\cdot 1}$	$n_{\cdot 2}$	$\cdots$	$n_{\cdot j}$	$\cdots$	$n_{\cdot s}$	n

行和和列和一共有$r+s$个参数，但是$\sum_{i=1}^{r}P_{i\cdot}=1$，$\sum_{j=1}^{s}P_{\cdot j}=1$，因此只有$(r-1)+(s-1)=r+s-2$个独立的参数

首先用极大似然估计对未知参数进行估计

$$L=\prod_{i=1}^{r}\prod_{j=1}^{s}P_{ij}^{n_{ij}}=\prod_{i=1}^{r}P_{i\cdot}^{n_{i\cdot}}\prod_{j=1}^{s}P_{\cdot j}^{n_{\cdot j}}$$ 抽取$P_{r\cdot}^{n_{r\cdot}}$和$P_{\cdot s}^{n_{\cdot s}}$作为"未独立变量"

$$=\prod_{i=1}^{r-1}P_{i\cdot}^{n_{i\cdot}}\left(1-\sum_{i=1}^{r-1}P_{i\cdot}\right)^{n_{r\cdot}}\prod_{j=1}^{s-1}P_{\cdot j}^{n_{\cdot j}}\left(1-\sum_{j=1}^{r-1}P_{\cdot j}\right)^{n_{\cdot s}}$$

$$\ln L=\sum_{i=1}^{r-1}n_{i\cdot}\ln P_{i\cdot}+n_{r\cdot}\ln\left(1-\sum_{i=1}^{r-1}P_{i\cdot}\right)+\sum_{j=1}^{s-1}n_{\cdot j}\ln P_{\cdot j}+n_{\cdot s}\ln\left(1-\sum_{j=1}^{r-1}P_{\cdot j}\right)$$

$$\frac{\partial\ln L}{\partial P_{i\cdot}}=\frac{-n_{r\cdot}}{1-\sum_{1}^{r-1}P_{i\cdot}}+\frac{n_{i\cdot}}{P_{i\cdot}}=0 \qquad \frac{\partial\ln L}{\partial P_{\cdot j}}=\frac{-n_{\cdot s}}{1-\sum_{1}^{r-1}P_{\cdot j}}+\frac{n_{\cdot j}}{P_{\cdot j}}=0$$

得$\hat{P}_{i\cdot}=\frac{n_{i\cdot}}{n}$，$\hat{P}_{\cdot j}=\frac{n_{\cdot j}}{n}$（概率似然于频率）

$$\therefore\chi^2=\sum_{i=1}^{r}\sum_{j=1}^{s}\frac{(n_{ij}-n\hat{P}_{i\cdot}\hat{P}_{\cdot j})^2}{n\hat{P}_{i\cdot}\hat{P}_{\cdot j}}=\sum_{i=1}^{r}\sum_{j=1}^{s}\frac{(n_{ij}-n_{i\cdot}n_{\cdot j}/n)^2}{n_{i\cdot}n_{\cdot j}/n}$$

当原假设成立时，χ^2的渐进分布为自由度$rs-(r+s-2)-1=(r-1)(s-1)$的χ^2分布

$$W=\{\chi^2\geq\chi_\alpha^2((r-1)(s-1))\}$$

题集

数学期望的应用

【1.17】设某种商品每周的需求量 X 是服从区间[10,30]上均匀分布的随机变量，而经销商店进货数量为区间[10,30]中的某一整数，商店每销售 1 单位商品可获利 500 元；若供大于求则削价处理，每处理 1 单位商品亏损 100 元；若供不应求，则可从外部调剂供应，此时每 1 单位商品仅获利 300 元，为使商店所获利润期望值不少于 9280 元，试确定最少进货量.

解 设进货数量为 a，则利润为

$$Y=\begin{cases}500a+(X-a)300, & a<X\leqslant 30\\ 500X-(a-X)100, & 10\leqslant X\leqslant a\end{cases}=\begin{cases}300X+200a, & a<X\leqslant 30\\ 600X-100a, & 10\leqslant X\leqslant a\end{cases}$$

利润期望

$$\begin{aligned}EY&=\int_{-\infty}^{+\infty}g(x)f(x)\mathrm{d}x=\int_{10}^{30}\frac{1}{20}\cdot g(x)\mathrm{d}x\\&=\frac{1}{20}\int_{10}^{a}(600x-100a)\mathrm{d}x+\frac{1}{20}\int_{a}^{30}(300x+200a)\mathrm{d}x\\&=\frac{1}{20}\left(600\frac{x^2}{2}-100ax\right)\Big|_{10}^{a}+\frac{1}{20}\left(300\frac{x^2}{2}+200ax\right)\Big|_{a}^{30}\\&=-7.5a^2+350a+5250.\end{aligned}$$

依题意，有

$$-7.5a^2+350a+5250\geqslant 9280 \quad 即 \quad 7.5a^2-350a+4030\leqslant 0,$$

解得 $20\frac{2}{3}\leqslant a\leqslant 26.$

故利润期望值不少于 9280 元的最少进货量为 21 单位.

方差的性质

【3.6】设随机变量 $X_1,X_2,\cdots,X_n(n>1)$ 独立同分布，且其方差为 $\sigma^2>0$. 令 $Y=\frac{1}{n}\sum_{i=1}^{n}X_i$，则_____.

(A) $\mathrm{Cov}(X_1,Y)=\frac{\sigma^2}{n}$　　(B) $\mathrm{Cov}(X_1,Y)=\sigma^2$

(C) $D(X_1+Y)=\frac{n+2}{n}\sigma^2$　　(D) $D(X_1-Y)=\frac{n+1}{n}\sigma^2$

解 本题用方差和协方差的运算性质直接计算即可，注意利用独立性有：

$$\mathrm{Cov}(X_i,X_i)=0,\quad i=2,3,\cdots,n$$

$$\begin{aligned}\mathrm{Cov}(X_1,Y)&=\mathrm{Cov}\left(X_1,\frac{1}{n}\sum_{i=1}^{n}X_i\right)=\frac{1}{n}\mathrm{Cov}(X_1,X_1)+\frac{1}{n}\sum_{i=2}^{n}\mathrm{Cov}(X_1,X_i)\\&=\frac{1}{n}DX_1=\frac{1}{n}\sigma^2.\end{aligned}$$

本题(C)，(D)两个选项的方差也直接计算得到：如

$$\begin{aligned}D(X_1+Y)&=D\left(\frac{1+n}{n}X_1+\frac{1}{n}X_2+\cdots+\frac{1}{n}X_n\right)=\frac{(1+n)^2}{n^2}\sigma^2+\frac{n-1}{n^2}\sigma^2\\&=\frac{n^2+3n}{n^2}\sigma^2=\frac{n+3}{n}\sigma^2,\end{aligned}$$

$$\begin{aligned}D(X_1-Y)&=D\left(\frac{n-1}{n}X_1-\frac{1}{n}X_2-\cdots-\frac{1}{n}X_n\right)=\frac{(n-1)^2}{n^2}\sigma^2+\frac{n-1}{n^2}\sigma^2\\&=\frac{n^2-n}{n^2}\sigma^2=\frac{n-1}{n}\sigma^2.\end{aligned}$$

故应选(A).

【4.2】 设随机变量 X 和 Y 独立同分布，记 $U=X-Y, V=X+Y$，则随机变量 U 与 V 必然（　　）.

(A) 不独立　　(B) 独立　　(C) 相关系数不为零　　(D) 相关系数为零

解
$$\begin{aligned}\mathrm{Cov}(U,V) &= E(UV)-[E(U)E(V)]\\ &= E(X^2-Y^2)-[E(X)]^2+[E(Y)]^2\\ &= E(X^2)-E(Y^2)-[E(X)]^2+[E(Y)]^2\\ &= [E(X^2)-(EX)^2]-[E(Y^2)-(EY)^2] = D(X)-D(Y)=0,\end{aligned}$$

所以

$$\rho_{UV}=\frac{\mathrm{Cov}(U,V)}{\sqrt{D(U)}\cdot\sqrt{D(V)}}=0.$$

故应选(D).

$Cov(X+Y, X-Y) = cov(X,X) - cov(X,Y) + cov(Y,X) - cov(Y,Y) = D(X) - D(Y) = 0$

题型 2. 利用公式求数字特征

【4.7】 设随机变量 X 的分布律为

$$P\{X=k\}=\frac{1}{1+a}\left(\frac{a}{1+a}\right)^k,\quad k=0,1,2,\cdots$$

其中 $a>0$ 为常数，求 $E(X)$，$D(X)$.

解法一　将 X 的分布律改写为

$$P\{X=k\}=pq^k,\quad k=0,1,2,\cdots$$

其中 $p=\frac{1}{1+a}$，$q=\frac{a}{1+a}$.

仿照几何分布的期望与方差计算方法可得：

$$E(X)=\sum_k kpq^k=pq\sum_k kq^{k-1}=pq\sum_k (q^k)'=pq\left(\frac{1}{1-q}\right)'=\frac{q}{p}=a.$$

同理可求　$D(X)=E(X^2)-[E(X)]^2=(1+a)a.$

解法二　直接利用几何分布的期望与方差计算结果.

设 Y 服从参数为 p 的几何分布. 则 $P\{Y=k\}=pq^{k-1}$，$k=1,2,\cdots$. 且

$$E(Y)=\frac{1}{p},\quad D(Y)=\frac{q}{p^2}.$$

而 $X=Y-1$，于是

$$E(X)=E(Y-1)=E(Y)-1=\frac{1}{p}-1=a,$$

$$D(X)=D(Y-1)=D(Y)=\frac{q}{p^2}=a(a+1).$$

【4.8】 设 $X\sim P(\lambda)$，求 $E\left(\frac{1}{X+1}\right)$.

$P(X=k)=pq^{k-1+r}$

即 $X-r\sim g(p)$

【4.16】 设随机变量 X 和 Y 的联合分布在以点(0,1),(1,0),(1,1)为顶点的三角形区域上服从均匀分布. 试求随机变量 $Z=X+Y$ 的方差.

解法一 (X,Y) 的联合密度为

$$f(x,y)=\begin{cases}2, & 0\leqslant x\leqslant 1,\ 1-x\leqslant y\leqslant 1\\ 0, & \text{其他}\end{cases}$$

由随机变量函数期望公式

$$E[g(X,Y)]=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}g(x,y)f(x,y)\mathrm{d}x\mathrm{d}y$$

可知,

$$EZ=E(X+Y)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}(x+y)f(x,y)\mathrm{d}x\mathrm{d}y=\int_0^1\mathrm{d}y\int_{1-y}^1 2(x+y)\mathrm{d}x$$

$$=\int_0^1(y^2+2y)\mathrm{d}y=\frac{4}{3},$$

而

$$EZ^2=E(X+Y)^2=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}(x+y)^2f(x,y)\mathrm{d}x\mathrm{d}y=\int_0^1\mathrm{d}y\int_{1-y}^1 2(x^2+2xy+y^2)\mathrm{d}x$$

$$=\int_0^1\left(2y+2y^2+\frac{3}{2}y^3\right)\mathrm{d}y=\frac{11}{6},$$

由方差的计算公式 $DZ=EZ^2-(EZ)^2=\frac{11}{6}-\frac{16}{9}=\frac{1}{18}$.

解法二 利用 $D(X+Y)=DX+DY+2\mathrm{Cov}(X,Y)$.

以 $f_X(x)$ 表示 X 的概率密度,则当 $x\leqslant 0$ 或 $x\geqslant 1$ 时,$f_X(x)=0$;当 $0<x<1$ 时,有

$$f_X(x)=\int_{-\infty}^{+\infty}f(x,y)\mathrm{d}y=\int_{1-x}^1 2\mathrm{d}y=2x,$$

因此

$$EX=\int_0^1 2x^2\mathrm{d}x=\frac{2}{3},\quad EX^2=\int_0^1 2x^3\mathrm{d}x=\frac{1}{2},$$

$$DX=EX^2-(EX)^2=\frac{1}{2}-\frac{4}{9}=\frac{1}{18}.$$

同理可得 $EY=\frac{2}{3}$, $DY=\frac{1}{18}$.

现在求 X 和 Y 的协方差

$$E(XY)=\iint_G 2xy\mathrm{d}x\mathrm{d}y=2\int_0^1 x\mathrm{d}x\int_{1-x}^1 y\mathrm{d}y=\frac{5}{12}$$

$$\mathrm{Cov}(X,Y)=E(XY)-EX\cdot EY=\frac{5}{12}-\frac{4}{9}=-\frac{1}{36},$$

于是

$$DZ=D(X+Y)=DX+DY+2\mathrm{Cov}(X,Y)=\frac{1}{18}+\frac{1}{18}-\frac{2}{36}=\frac{1}{18}.$$

解法三 由于 X,Y 服从均匀分布,所以当 $z<1$ 时,$F(z)=0$;

当 $z>2$ 时,$F(z)=1$;

当 $1\leqslant z\leqslant 2$ 时,$F(z)=P\{X+Y\leqslant z\}=\frac{S_D'}{S_D}$,

因为 $S_D'=\frac{1}{2}-S_\triangle=\frac{1}{2}-\frac{1}{2}(2-z)^2$, $S_D=\frac{1}{2}$,

所以 $F(z)=1-(2-z)^2$,

故 $f(z)=F'(z)=\begin{cases}2(2-z), & 1\leqslant z\leqslant 2\\ 0, & \text{其他}\end{cases}$

所以 $E(Z)=\frac{4}{3}$, $E(Z^2)=\frac{11}{6}$.

故 $D(Z)=D(X+Y)=E(Z^2)-(E(Z))^2=\frac{1}{18}$.

点评 对本题而言,解法一最为简洁.

【4.18】 设两个随机变量 X,Y 相互独立，且都服从均值为 0，方差为 $\frac{1}{2}$ 的正态分布，求随机变量 $|X-Y|$ 的期望与方差.

解法一 按照一维变量的函数处理.

令 $Z=X-Y$，由于 $X\sim N(0,\frac{1}{2})$，$Y\sim N(0,\frac{1}{2})$，且 X 和 Y 相互独立，故 $Z\sim N(0,1)$.

$$E(|X-Y|)=E(|Z|)=\int_{-\infty}^{+\infty}|z|\frac{1}{\sqrt{2\pi}}e^{-\frac{z^2}{2}}dz=\frac{2}{\sqrt{2\pi}}\int_0^{+\infty}ze^{-\frac{z^2}{2}}dz=\sqrt{\frac{2}{\pi}}$$

因为

$$D(|X-Y|)=D(|Z|)=E(|Z|^2)-[E(|Z|)]^2=E(Z^2)-[E(|Z|)]^2$$

而 $E(Z^2)=D(Z)=1$

所以 $D(|X-Y|)=1-\frac{2}{\pi}$.

解法二 按照二维随机变量的函数处理.

利用公式

$$E[g(X,Y)]=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}g(x,y)f(x,y)dxdy,$$

$$E(|X-Y|)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}|x-y|f(x,y)dxdy=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}|x-y|\cdot\frac{1}{\pi}e^{-(x^2+y^2)}dxdy$$

$$=\sqrt{\frac{2}{\pi}}\quad\text{(利用极坐标计算)}$$

$$E(|X-Y|^2)=E[(X-Y)^2]=D(X-Y)+[E(X-Y)]^2=1$$

故 $D(|X-Y|)=1-\frac{2}{\pi}$.

点评 解法一比解法二简便.

【4.28】 设 $X\sim N(0,1)$，而 $Y=X^n$（n 为正整数），求 ρ_{XY}.

解 因为 $X\sim N(0,1)$，则 $E(X)=0$，$D(X)=1$. 另外当 $X\sim N(0,1)$ 时，可利用分部积分法或者 Γ 函数的公式得到下面结论：

$$E(X^{2n+1})=0,$$

$$E(X^{2n})=(2n-1)!!=(2n-1)(2n-3)\cdots\cdots3\cdot1.$$

故

$$\rho_{XY}=\frac{\mathrm{Cov}(X,Y)}{\sqrt{DX}\cdot\sqrt{DY}}=\frac{E(XY)-EX\cdot EY}{\sqrt{DX}\cdot\sqrt{DY}}=\frac{E(X^{n+1})}{\sqrt{D(X^n)}}=\frac{E(X^{n+1})}{\sqrt{E(X^{2n})-(EX^n)^2}}$$

$$=\begin{cases}0, & \text{当 } n \text{ 为偶数时}\\ \dfrac{n!!}{\sqrt{(2n-1)!!}}, & \text{当 } n \text{ 为奇数时}\end{cases}$$

【4.48】假设由自动线加工的某种零件的内径 X(毫米)服从正态分布 $N(\mu,1)$,内径小于 10 或大于 12 的为不合格品,其余为合格品,销售每件合格品获利,销售每件不合格品亏损. 已知销售利润 T(单位:元)与销售零件的内径 X 有如下关系:

$$T=\begin{cases}-1, & \text{若 } X<10\\ 20, & \text{若 } 10\leqslant X\leqslant 12\\ -5, & \text{若 } X>12\end{cases}$$

问平均内径 μ 取何值时,销售一个零件的平均利润最大?

解 由条件知,平均利润为

$$\begin{aligned}E(T)&=20P\{10\leqslant X\leqslant 12\}-P\{X<10\}-5P\{X>12\}\\&=20[\Phi(12-\mu)-\Phi(10-\mu)]-\Phi(10-\mu)-5[1-\Phi(12-\mu)]\\&=25\Phi(12-\mu)-21\Phi(10-\mu)-5,\end{aligned}$$

其中 $\Phi(x)$ 是标准正态分布函数,设 $\varphi(x)$ 为标准正态密度,则有

$$\frac{dE(T)}{d\mu}=-25\varphi(12-\mu)+21\varphi(10-\mu)$$

令其等于 0,得

$$\frac{-25}{\sqrt{2\pi}}e^{-\frac{(12-\mu)^2}{2}}+\frac{21}{\sqrt{2\pi}}e^{-\frac{(10-\mu)^2}{2}}=0,$$

即 $25e^{-\frac{(12-\mu)^2}{2}}=21e^{-\frac{(10-\mu)^2}{2}}$,

由此得 $\mu=\mu_0=11-\frac{1}{2}\ln\frac{25}{11}\approx 10.9$.

由题意知,当 $\mu=\mu_0\approx 10.9$ 毫米时,平均利润最大.

【4.54】设 (X,Y) 服从二维正态分布,且有 $D(X)=\sigma_X^2$,$D(Y)=\sigma_Y^2$,证明当 $a^2=\frac{\sigma_X^2}{\sigma_Y^2}$ 时随机变量 $W=X-aY$ 与 $V=X+aY$ 相互独立.

解

$$E(W)=E(X)-aE(Y)=\mu_X-a\mu_Y$$

$$E(V)=E(X)+aE(Y)=\mu_X+a\mu_Y$$

$$D(W)=D(X)+a^2D(Y)-2a\mathrm{Cov}(X,Y)=\sigma_X^2+a^2\sigma_Y^2-2a\rho_{XY}\sigma_X\sigma_Y$$

$$D(V)=D(X)+a^2D(Y)+2a\mathrm{Cov}(X,Y)=\sigma_X^2+a^2\sigma_Y^2+2a\rho_{XY}\sigma_X\sigma_Y$$

$$\begin{aligned}E(WV)&=E(X^2-a^2Y^2)=E(X^2)-a^2E(Y^2)=D(X)+\mu_X^2-a^2[D(Y)+\mu_Y^2]\\&=\sigma_X^2+\mu_X^2-a^2\sigma_Y^2-a^2\mu_Y^2\end{aligned}$$

$$\begin{aligned}\mathrm{Cov}(W,V)&=E(WV)-E(W)E(V)=\sigma_X^2+\mu_X^2-a^2\sigma_Y^2-a^2\mu_Y^2-(\mu_X-a\mu_Y)(\mu_X+a\mu_Y)\\&=\sigma_X^2-a^2\sigma_Y^2\end{aligned}$$

由于 (W,V) 服从二维正态分布,W 与 V 相互独立的充要条件是 W 与 V 不相关,即 $\mathrm{Cov}(W,V)=0$,则 $\sigma_X^2-a^2\sigma_Y^2=0$,即

$$a^2=\frac{\sigma_X^2}{\sigma_Y^2}.$$

【1.52】 设 $X_1,X_2,\cdots,X_n$ 是来自总体 X 的样本，总体 X 的分布函数为 $F(x)$，密度函数为 $f(x)$，记 $Y=\max(X_1,X_2,\cdots,X_n)$，　$Z=\min(X_1,X_2,\cdots,X_n)$，
试求 Y,Z 的密度函数及 (Y,Z) 的联合密度函数.

解　因为 $X_1,X_2,\cdots,X_n$ 独立同分布，且 X_i 分布函数为 $F(x)$，则由第三章公式可得：

$$F_Y(y)=[F(y)]^n,\qquad F_Z(z)=1-[1-F(z)]^n,$$

故　$f_Y(y)=F'_Y(y)=nF^{n-1}(y)f(y)$，

$f_Z(z)=F'_Z(z)=n[1-F(z)]^{n-1}f(z)$.

设 (Y,Z) 的联合分布函数为 $G(y,z)$，$G(y,z)=P\{Y\leqslant y,Z\leqslant z\}$，

当 $y<z$ 时，$G(y,z)=P\{Y\leqslant y\}=F_Y(y)=[F(y)]^n$，

当 $y\geqslant z$ 时，

$$\begin{aligned}G(y,z)&=P\{Y\leqslant y,Z\leqslant z\}=P\{Y\leqslant y\}-P\{Y\leqslant y,Z>z\}\\&=P\{Y\leqslant y\}-P\{\max(X_i)\leqslant y,\min(X_i)>z\}\\&=P\{Y\leqslant y\}-P\{z<X_1\leqslant y,z<X_2\leqslant y,\cdots,z<X_n\leqslant y\}\\&=P\{Y\leqslant y\}-[P\{z<X_i\leqslant y\}]^n\\&=[F(y)]^n-[F(y)-F(z)]^n,\end{aligned}$$

即
$$G(y,z)=\begin{cases}[F(y)]^n, & y<z\\ [F(y)]^n-[F(y)-F(z)]^n, & y\geqslant z\end{cases}$$

故 (Y,Z) 的联合密度为

$$g(y,z)=\frac{\partial^2 G}{\partial y\partial z}=\begin{cases}n(n-1)f(y)f(z)[F(y)-F(z)]^{n-2}, & y\geqslant z\\ 0, & y<z\end{cases}$$